**UNIVERSIDAD DE CUNDINAMARCA**
**ESPECIALIZACIÓN EN INTELIGENCIA ARTIFICIAL**
**PROCESAMIENTO DE LENGUAJE NATURAL**
**DOCENTE: PAUL ALEXANDER DÍAZ MONTAÑA**

# INFORME DE PROYECTO: ESTADÍSTICAS DE YOUTUBE – AVANCES III
# ITERACIÓN Y MEJORA DEL MODELO DE DESEMPEÑO DE VIDEOS A PARTIR DE SUS COMENTARIOS

**ESTUDIANTE: YOHAN NICOLÁS GÓMEZ CASTAÑEDA**
**CC: 1233903906**

**FECHA: 18 DE OCTUBRE DE 2026**
**REPOSITORIO: https://github.com/Nicolas2322/proyecto-estadisticas-youtube**

**Contenido**

1. Introducción 3
2. Respuestas a las Preguntas de la Entrega 3
3. Metodología de Iteración 4
    3.1 Protocolo de Evaluación y Criterio de Adopción 4
    3.2 Herramientas Utilizadas 4
4. Iteraciones de la Etapa A: Clasificación de Sentimiento 5
    4.1 Descripción de las Iteraciones 5
    4.2 Resultados de la Etapa A 7
    4.3 Significancia Estadística de la Mejora 8
5. Iteraciones de la Etapa B: Desempeño del Video 8
    5.1 Descripción de las Iteraciones 8
    5.2 Resultados de la Etapa B 9
    5.3 Optimización Bayesiana de Hiperparámetros 10
    5.4 Clasificación del Éxito Relativo 11
6. Modelo Seleccionado 11
7. Variables Seleccionadas 12
8. ¿Es Suficiente un Solo Modelo? 13
9. Robustez e Incertidumbre del Modelo 14
    9.1 Análisis de Sensibilidad 14
    9.2 Intervalos de Predicción Conformales 14
10. Lecciones de la Iteración y Próximos Pasos 15
11. Conclusiones 15
12. Referencias 15

**Proyecto Estadísticas de YouTube – Avances III: Iteración y Mejora del Modelo**

## 1. Introducción

El presente informe documenta la tercera etapa del proyecto, enfocada en la iteración del modelo y en las herramientas probadas para mejorarlo. En Avances II se estableció una arquitectura de dos etapas: un clasificador de sentimiento por comentario (etapa A), basado en una máquina de soporte vectorial (SVM) lineal con TF-IDF de palabras y caracteres, y un modelo de desempeño por video (etapa B), basado en XGBoost, que estima el logaritmo de las vistas a partir de variables agregadas de los comentarios. Ese punto de partida alcanzó un F1-macro de 0,708 en la etapa A y un $R^2$ de 0,787 en la etapa B.

En esta etapa se ejecutaron 23 iteraciones, siete en la etapa A y dieciséis en la etapa B (incluidos los componentes individuales del ensamble y los análisis de robustez e incertidumbre), todas evaluadas con las mismas particiones de validación cruzada y registradas en MLflow como bitácora de experimentos, siguiendo los principios de seguimiento y reproducibilidad de MLOps descritos por Kreuzberger et al. (2023). En la etapa A, la combinación de un preprocesamiento orientado a redes sociales, variables léxicas y de contexto, *embeddings* GloVe entrenados con tuits y un ajuste anidado de umbrales elevó el F1-macro a 0,757 (+0,049; IC 95 %: 0,041–0,057), con la mayor ganancia en la clase negativa (+0,072). En la etapa B, ninguna variable nueva superó a las existentes y la optimización bayesiana no mejoró los hiperparámetros, pero un ensamble por *stacking* de cuatro modelos elevó el $R^2$ a 0,793 y redujo el error absoluto de forma significativa (prueba de Wilcoxon, $p \approx 2 \cdot 10^{-9}$). Se incorporaron además intervalos de predicción conformales con una cobertura empírica del 90,3 %.

## 2. Respuestas a las Preguntas de la Entrega

La Tabla 1 sintetiza la respuesta a cada pregunta planteada para la semana 9; las secciones siguientes desarrollan cada punto.

**Tabla 1**

*Respuestas a las preguntas de la entrega*

| Pregunta | Respuesta |
|---|---|
| ¿Qué iteraciones se realizaron y qué mejoraron? | Siete iteraciones en la etapa A (preprocesamiento, variables léxicas y de contexto, *embeddings* GloVe, umbrales por clase y *stacking*) y dieciséis en la etapa B (sentimiento mejorado, variables y *embeddings* del título, *embeddings* de comentarios, selección por SHAP, Optuna, ensambles y análisis de robustez). La etapa A mejoró 0,049 de F1-macro; la etapa B, 0,006 de $R^2$ y 3,3 % de error absoluto (secciones 4 y 5). |

| Pregunta | Respuesta |
|---|---|
| ¿Cuál fue el modelo seleccionado? | Etapa A: SVM lineal híbrido (TF-IDF de palabras y caracteres sobre texto normalizado, 11 variables léxicas, categoría y *embeddings* GloVe Twitter) con umbrales por clase ajustados de forma anidada. Etapa B: *stacking* de XGBoost, HistGradientBoosting, Random Forest y Ridge con meta-modelo RidgeCV. Éxito relativo: regresión logística (sección 6). |
| ¿Cuál fue su desempeño y bajo qué métricas? | Etapa A: F1-macro 0,757 ± 0,008; exactitud 0,820; F1 negativo 0,664. Etapa B: $R^2$ 0,793 ± 0,016; MAE 0,347 en $\log_{10}$ (factor ×2,22); ρ de Spearman 0,893; intervalos del 90 % con cobertura del 90,3 %. Éxito relativo: ROC-AUC 0,879; puntuación de Brier 0,141. |
| ¿Cuántos modelos se probaron? | Veintitrés iteraciones con nueve algoritmos distintos (SVM lineal, regresión logística, Complement NB, XGBoost, HistGradientBoosting, Random Forest, Ridge y los ensambles por promedio y *stacking*), más 125 ensayos de optimización bayesiana (25 por cada uno de los cinco folds externos). Todas las corridas se registraron en MLflow. |
| ¿Qué herramientas se usaron para determinar el modelo? | Validación cruzada con particiones fijas, validación cruzada anidada, Optuna (TPE), SHAP, prueba de McNemar, *bootstrap*, prueba de Wilcoxon, predicción conformal y MLflow (Tabla 2). |
| ¿Es suficiente un solo modelo? | No. Además de la arquitectura de dos etapas, en la etapa B el ensamble supera a todos sus componentes individuales; en cambio, en la etapa A el *stacking* no mejoró al SVM híbrido. La respuesta depende de la diversidad de errores entre modelos (sección 8). |
| ¿Qué variables se seleccionaron para predecir? | Etapa A: n-gramas de palabras y caracteres, 11 variables léxicas, la categoría y 100 dimensiones GloVe. Etapa B: las 32 variables de Avances II (sentimiento, interacción con comentarios, 20 tópicos, antigüedad y categoría); las 4 familias de variables nuevas se descartaron por no aportar (sección 7). |

## 3. Metodología de Iteración

### 3.1 Protocolo de Evaluación y Criterio de Adopción

Para que las iteraciones fueran comparables, todas se evaluaron con las mismas cinco particiones de validación cruzada con semilla fija (42): estratificadas por clase en la etapa A (18.139 comentarios) y aleatorias en la etapa B (1.867 videos). La métrica principal fue el F1-macro en la etapa A, por el desbalance de clases, y el $R^2$ sobre $\log_{10}$(vistas) en la etapa B. Cada iteración modificó un solo aspecto respecto a la mejor versión vigente; se adoptó cuando mejoró la métrica principal media, y las diferencias menores a 0,002 se trataron como empates, que solo se adoptaron si no añadían complejidad al modelo. Cualquier componente con hiperparámetros propios (umbrales, Optuna, meta-modelos) se ajustó dentro de cada partición de entrenamiento, mediante validación cruzada anidada, para evitar estimaciones optimistas.

### 3.2 Herramientas Utilizadas

La Tabla 2 resume las herramientas incorporadas en esta etapa y la función que cumplieron.

**Tabla 2**

*Herramientas utilizadas en la iteración del modelo*

| Herramienta | Uso en el proyecto | Iteraciones |
|---|---|---|
| emoji y expresiones regulares | Conversión de emojis a texto, reducción de alargamientos y marcado de negación | A1 |
| VADER y TextBlob | Variables léxicas de polaridad, intensidad y subjetividad | A2 |
| Gensim y GloVe Twitter | *Embeddings* de 100 dimensiones preentrenados con 2.000 millones de tuits (Pennington et al., 2014) | A3, B3, B4 |
| scikit-learn | Canalizaciones, validación cruzada, *stacking* y modelos lineales y de árboles (Pedregosa et al., 2011) | Todas |
| XGBoost | Modelo de *gradient boosting* de la etapa B (Chen y Guestrin, 2016) | B0–B9 |
| Optuna | Optimización bayesiana de hiperparámetros con el muestreador TPE (Akiba et al., 2019) | B7 |
| SHAP | Explicación del modelo y selección de variables por valores de Shapley (Lundberg y Lee, 2017) | B6, modelo final |
| Predicción conformal | Intervalos de predicción con cobertura garantizada (Angelopoulos y Bates, 2021); implementación propia | B10 |
| MLflow | Registro de parámetros y métricas de cada iteración en una base SQLite (Zaharia et al., 2018) | Todas |
| SciPy | Pruebas de McNemar y de Wilcoxon e intervalos *bootstrap* | Comparación final |

## 4. Iteraciones de la Etapa A: Clasificación de Sentimiento

### 4.1 Descripción de las Iteraciones

El análisis de errores de Avances II mostró que la debilidad principal del clasificador era la clase negativa (F1 = 0,59), con un 22 % de comentarios negativos confundidos con neutrales. Las iteraciones se diseñaron para atacar las causas probables de esa confusión: información perdida en la limpieza, ausencia de conocimiento léxico previo, falta de contexto temático y vocabulario poco frecuente. La Tabla 3 describe cada iteración y su resultado.

**Tabla 3**

*Iteraciones de la etapa A y decisión adoptada*

| Iteración | Cambio y justificación | F1-macro | Δ | Decisión |
|---|---|---|---|---|
| A0 Base | SVM lineal con TF-IDF de palabras (1-2 gramas) y caracteres (2-5 gramas), C = 0,1, ajustado en Avances II. | 0,708 ± 0,011 | – | Punto de partida |

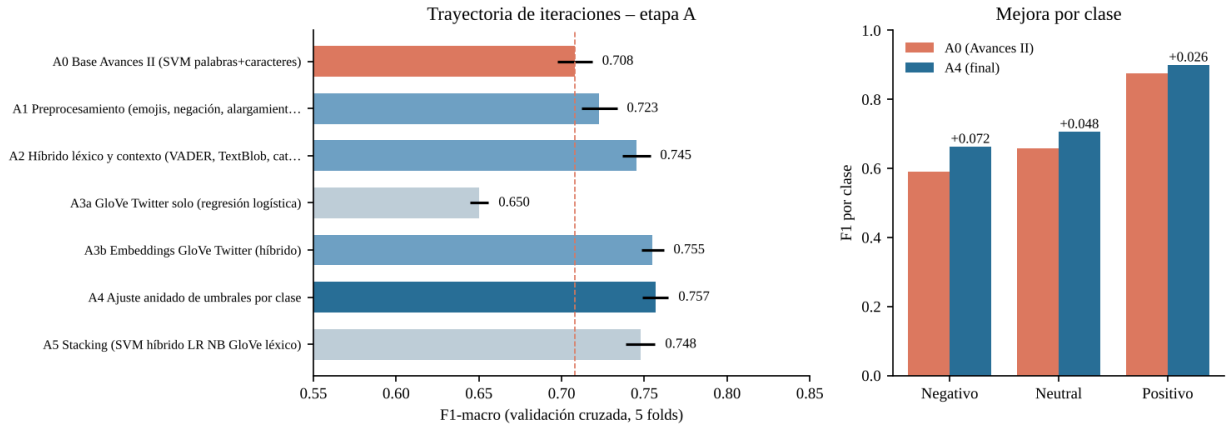
| Iteración | Cambio y justificación | F1-macro | Δ | Decisión |
|---|---|---|---|---|
| A1 Preprocesamiento | Emojis convertidos a palabras (😂 → *face_with_tears_of_joy*), alargamientos reducidos (*sooo* → *soo*), contracciones negativas expandidas y marcado de negación en una ventana de tres palabras (*not good* → *not NEG_good*). La limpieza anterior eliminaba los emojis y no distinguía «good» de «not good». | 0,723 ± 0,011 | +0,015 | Adoptada |
| A2 Híbrido léxico y contexto | Se añadieron 11 variables léxicas (VADER, TextBlob, longitud, signos, emojis, proporción de mayúsculas) y la categoría del video. El léxico aporta conocimiento previo de polaridad y la categoría ajusta la tasa base de negatividad, que varía del 2 % al 55 % según el tema (Avances II, análisis 5). | 0,745 ± 0,009 | +0,022 | Adoptada |
| A3a GloVe solo | Promedio de *embeddings* GloVe Twitter con regresión logística, como prueba aislada de la representación densa. | 0,650 ± 0,006 | −0,095 | Descartada como modelo aislado |
| A3b + GloVe (híbrido) | Las 100 dimensiones GloVe se añadieron al modelo A2. Los *embeddings* asignan representaciones cercanas a palabras sinónimas o mal escritas que no comparten n-gramas. | 0,755 ± 0,007 | +0,010 | Adoptada |
| A4 Umbrales por clase | Sesgos aditivos por clase sobre la función de decisión, elegidos dentro de cada partición de entrenamiento mediante validación cruzada interna de tres folds, para maximizar el F1-macro. | **0,757 ± 0,008** | +0,002 | **Adoptada: modelo final** (empate sin costo de inferencia) |
| A5 *Stacking* | Meta-modelo de regresión logística sobre cinco clasificadores base: SVM híbrido, regresión logística, Complement NB, GloVe y léxico. | 0,748 ± 0,009 | −0,009 | Descartada |

*Nota.* F1-macro: media ± desviación estándar en cinco folds estratificados. Δ = cambio frente a la mejor iteración vigente. El valor de A0 (0,708) difiere levemente del 0,710 de Avances II porque en este informe se usa el C = 0,1 hallado en la búsqueda en malla, en lugar del C = 0,3 inicial. La cobertura de GloVe sobre el vocabulario de los comentarios fue del 91,9 %.

## 4.2 Resultados de la Etapa A

**Figura 1**

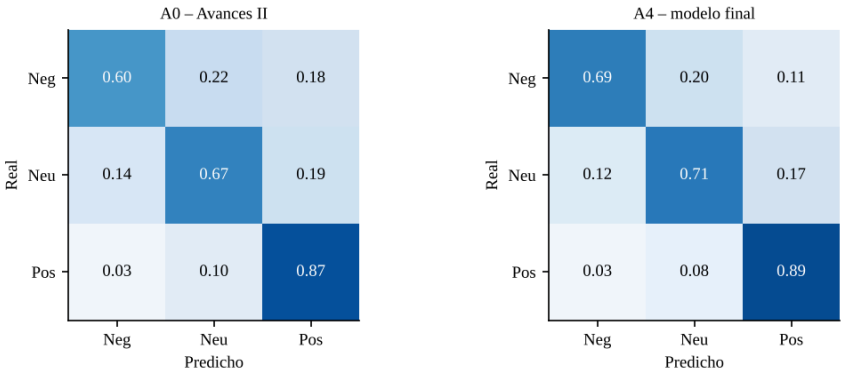
*Trayectoria de las iteraciones de la etapa A y mejora del F1 por clase*




**Análisis:** las mayores ganancias provinieron de iteraciones guiadas por el análisis de errores. El preprocesamiento (+0,015) recuperó información que la limpieza anterior destruía (emojis y negaciones), y la incorporación del léxico y la categoría (+0,022) fue el mayor salto individual, lo que confirma que el contexto temático hallado en Avances II tiene valor predictivo para el sentimiento. GloVe por sí solo rinde menos que el TF-IDF (0,650), pero combinado aporta +0,010, ya que ambos tipos de representación son complementarios. El ajuste de umbrales produjo un empate técnico (+0,002, inferior a la desviación entre folds); se conservó porque solo suma un sesgo constante a la predicción. La mejora más relevante para el proyecto se dio en la clase negativa: su F1 pasó de 0,591 a 0,664 (+0,072) y su sensibilidad de 0,598 a 0,686.

**Figura 2**

*Matrices de confusión normalizadas del modelo base y del modelo final*



**Análisis:** la proporción de comentarios negativos clasificados como positivos se redujo del 17,8 % al 11,2 %, y la de negativos confundidos con neutrales del 22,4 % al 20,2 %. La exactitud global subió de 0,782 a 0,820. La confusión residual entre negativo y neutral se concentra en críticas expresadas sin palabras negativas, como «Imagine losing the cursor on that screen and trying to find it 💀» o «The price of the road-going Kawasaki really tells how overpriced the push bikes are», cuya interpretación requiere ironía o conocimiento del mundo que los modelos de bolsa de palabras no capturan.

### 4.3 Significancia Estadística de la Mejora

Para comprobar que la mejora no se debe al azar, se compararon las predicciones fuera de fold del modelo base y del final sobre los 18.139 comentarios. La prueba de McNemar indica que el modelo final acierta en 1.558 comentarios en los que el base falla, frente a 870 en el caso contrario ($\chi^2 = 194{,}4$; $p \approx 3{,}5 \cdot 10^{-44}$). Un *bootstrap* de 1.000 remuestreos ubica la mejora del F1-macro entre 0,041 y 0,057 con un 95 % de confianza, por lo que la ganancia es estadísticamente sólida.

## 5. Iteraciones de la Etapa B: Desempeño del Video

### 5.1 Descripción de las Iteraciones

Las iteraciones de la etapa B exploraron cuatro frentes: mejores variables de texto, nuevas fuentes de información, ajuste de hiperparámetros y combinación de modelos. La Tabla 4 resume cada iteración.

**Tabla 4**

*Iteraciones de la etapa B y decisión adoptada*

| Iteración | Cambio y justificación | $R^2$ | MAE | Decisión |
|---|---|---|---|---|
| B0 Base | XGBoost con las 32 variables de Avances II. | 0,787 ± 0,018 | 0,359 | Punto de partida |
| B1 Sentimiento mejorado | Proporciones de sentimiento calculadas con el clasificador final de la etapa A. | 0,780 ± 0,018 | 0,362 | Descartada (−0,007) |
| B2 Variables del título | Once variables de formato del título: longitud, mayúsculas, dígitos, signos, separadores, *#shorts* y «official». El título está disponible desde la publicación. | 0,787 ± 0,018 | 0,360 | Descartada (+0,000) |
| B3 *Embeddings* del título | Promedio GloVe del título reducido con PCA a 10 componentes. | 0,789 ± 0,019 | 0,357 | Descartada (empate, +0,002) |
| B4 *Embeddings* de comentarios | Promedio GloVe de todos los comentarios del video (PCA 10). | 0,781 ± 0,022 | 0,364 | Descartada (−0,006) |

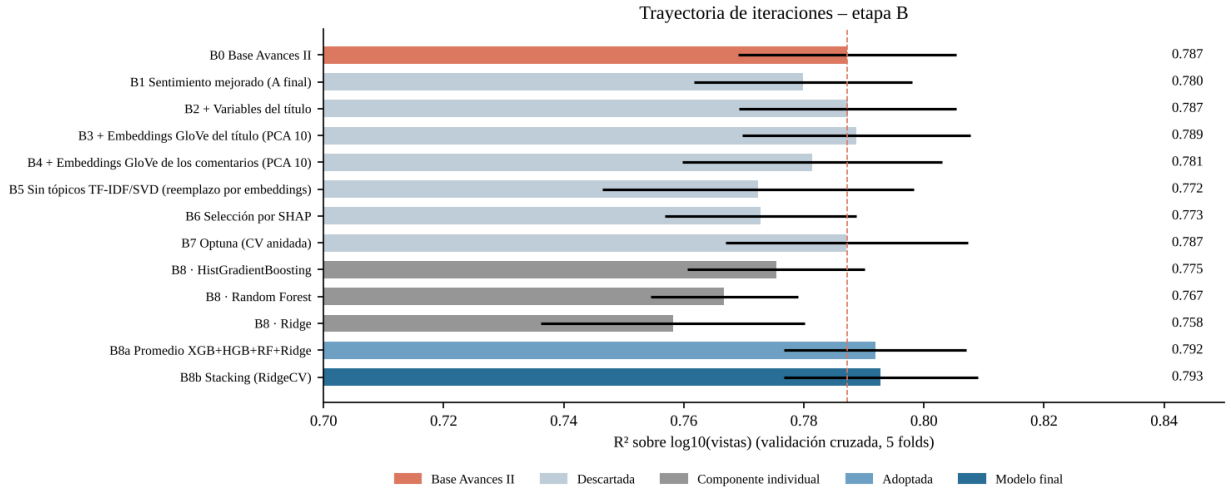
| Iteración | Cambio y justificación | $R^2$ | MAE | Decisión |
|---|---|---|---|---|
| B5 *Embeddings* en lugar de tópicos | Sustitución de los 20 tópicos TF-IDF/SVD por los *embeddings* de comentarios. | 0,772 ± 0,026 | 0,373 | Descartada (−0,015) |
| B6 Selección por SHAP | En cada fold se conservaron las variables que suman el 95 % de la importancia SHAP (≈ 36 de 72 columnas). | 0,773 ± 0,016 | 0,369 | Descartada (−0,014) |
| B7 Optuna anidado | Optimización bayesiana de ocho hiperparámetros: 25 ensayos con validación interna de tres folds en cada uno de los cinco folds externos. | 0,787 ± 0,020 | 0,360 | Descartada (−0,000) |
| B8a Ensamble por promedio | Promedio de XGBoost, HistGradientBoosting, Random Forest y Ridge. | 0,792 ± 0,015 | 0,349 | Adoptada (+0,005) |
| **B8b *Stacking*** | Los mismos cuatro modelos combinados por un meta-modelo RidgeCV entrenado con predicciones internas de cinco folds. | **0,793 ± 0,016** | **0,347** | **Adoptada: modelo final** |

*Nota.* $R^2$ y MAE sobre $\log_{10}$(vistas), media de cinco folds. Componentes individuales con las mismas variables: HistGradientBoosting 0,775; Random Forest 0,767; Ridge 0,758. Las iteraciones B9 y B10 (robustez e incertidumbre) se presentan en la sección 9.

## 5.2 Resultados de la Etapa B

**Figura 3**

*Trayectoria de las iteraciones de la etapa B*




**Análisis:** el resultado más informativo de esta etapa es negativo: ninguna de las cinco iteraciones de variables superó al conjunto de Avances II. Mejorar el clasificador de sentimiento (B1) incluso empeoró levemente la predicción, lo que refuerza el hallazgo de Avances II de que el tono de los comentarios explica poco del alcance. El título, aunque está disponible desde la publicación, no añade información a la que ya contienen los comentarios y la categoría. Los

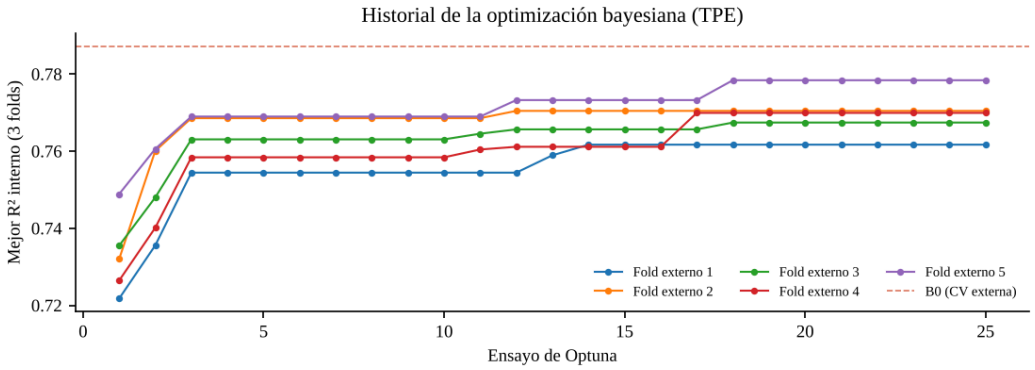
*embeddings* densos de comentarios rinden menos que los tópicos TF-IDF/SVD, que capturan mejor los temas concretos de cada nicho. La selección por SHAP también empeoró el resultado, ya que muchas variables con baja importancia individual aportan en conjunto. En cambio, combinar modelos sí mejoró: los cuatro algoritmos cometen errores distintos y su ensamble supera al mejor de ellos.

### 5.3 Optimización Bayesiana de Hiperparámetros

La búsqueda en malla de Avances II exploró una región limitada del espacio de hiperparámetros. Para descartar que existiera una configuración mejor fuera de ella, se aplicó Optuna con el muestreador TPE sobre ocho hiperparámetros de XGBoost: número de árboles, tasa de aprendizaje, profundidad, peso mínimo por hoja, submuestreo de filas y columnas, y regularización L1 y L2. La búsqueda se anidó: en cada fold externo se optimizó con una validación interna de tres folds y el modelo resultante se evaluó en el fold externo, que no participó en la búsqueda (Figura 4).

**Figura 4**

*Historial de la optimización bayesiana en cada fold externo*




**Análisis:** la mejor configuración se encuentra entre los ensayos 12 y 18, y a partir del ensayo 15 la mejora interna es inferior a 0,009; la optimización produce un $R^2$ externo de 0,787, idéntico al de los hiperparámetros de Avances II. Las configuraciones elegidas son coherentes entre folds (profundidad 5, tasa de aprendizaje ≈ 0,035, alrededor de 400 árboles, submuestreo de columnas ≈ 0,56) y distintas de las iniciales (profundidad 6, tasa 0,06, 800 árboles), lo que indica una superficie de respuesta plana con varias configuraciones equivalentes. Se concluye que el desempeño de XGBoost está limitado por la información disponible y no por los hiperparámetros, por lo que el esfuerzo de mejora debía dirigirse a la combinación de modelos.

### 5.4 Clasificación del Éxito Relativo

Para la tarea complementaria, que determina si un video supera la mediana de vistas de su categoría, se compararon la regresión logística (C = 100, ajustada en Avances II) y un clasificador XGBoost con las variables finales. La regresión logística obtuvo un ROC-AUC de 0,879 ± 0,004 y una puntuación de Brier de 0,141, frente a 0,857 ± 0,008 y 0,158 de XGBoost. Se mantiene la regresión logística: discrimina mejor, sus probabilidades están mejor calibradas (menor Brier) y es más estable entre folds.

## 6. Modelo Seleccionado

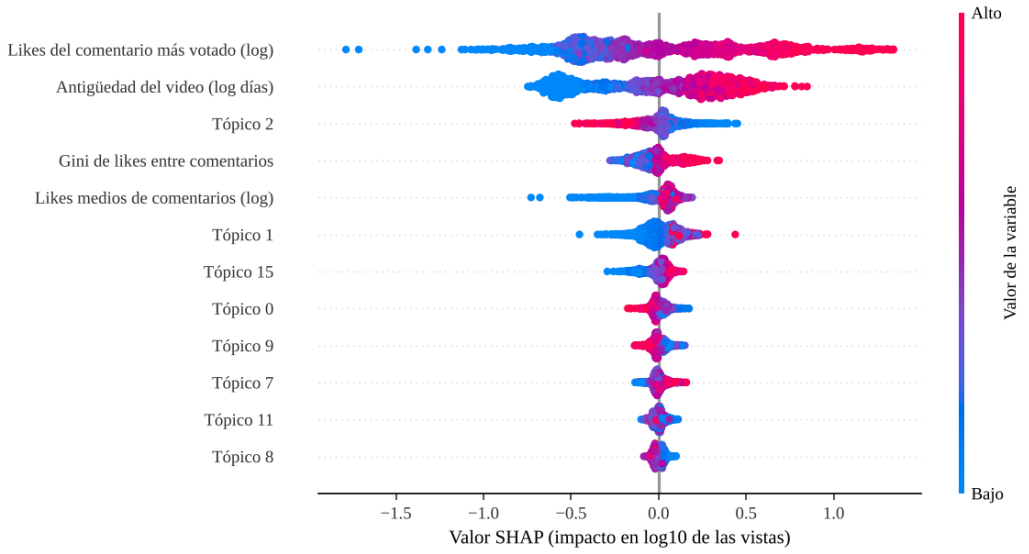
El modelo resultante de la iteración conserva la arquitectura de dos etapas y modifica sus componentes:

- Etapa A: SVM lineal (C = 0,1, pesos de clase balanceados) sobre la concatenación de TF-IDF de palabras y caracteres del texto normalizado, 11 variables léxicas estandarizadas, la categoría del video en codificación *one-hot* y las 100 dimensiones GloVe Twitter; a la función de decisión se suma un sesgo por clase ajustado de forma anidada. Desempeño: F1-macro 0,757; exactitud 0,820.
- Etapa B: *stacking* de XGBoost, HistGradientBoosting, Random Forest y Ridge sobre las 32 variables de Avances II, combinados por un meta-modelo RidgeCV. Desempeño: $R^2$ 0,793; MAE 0,347 (factor ×2,22); ρ de Spearman 0,893.
- Éxito relativo: regresión logística (C = 100) con ROC-AUC de 0,879.

La justificación de cada elección es empírica: es la mejor configuración bajo el mismo protocolo de evaluación, su ventaja frente a la base es estadísticamente significativa (McNemar en la etapa A; Wilcoxon sobre los errores absolutos en la etapa B, $p \approx 2{,}2 \cdot 10^{-9}$, con mejora en cuatro de cinco folds) y su costo computacional es compatible con un servicio en línea. La Figura 5 explica las predicciones del componente XGBoost mediante valores SHAP.

**Figura 5**

*Valores SHAP de las doce variables más influyentes en el componente XGBoost*




**Análisis:** cada punto es un video y su posición horizontal indica cuánto eleva o reduce la predicción de $\log_{10}$(vistas). Los likes del comentario más votado son la variable más influyente (impacto medio de 0,43 órdenes de magnitud): valores altos (rojo) elevan la predicción hasta en un orden de magnitud. Le sigue la antigüedad (0,35), con el patrón esperado de mayor acumulación de vistas en videos más antiguos. El Gini de los likes muestra que una conversación dominada por un comentario destacado se asocia a más vistas, y algunos tópicos de texto (2, 1 y 15) aportan efectos temáticos específicos. Las variables de sentimiento no aparecen entre las doce primeras, lo que es coherente con el resultado de la iteración B1.

## 7. Variables Seleccionadas

La Tabla 5 resume las variables que conforman el modelo final y las que se evaluaron sin ser incorporadas.

**Tabla 5**

*Variables del modelo final y variables evaluadas sin ser incorporadas*

| Etapa | Variables incorporadas | Evaluadas y no incorporadas |
|---|---|---|
| A | TF-IDF de palabras (1-2 gramas) y caracteres (2-5 gramas) del texto normalizado; 11 variables léxicas; categoría; 100 dimensiones GloVe Twitter | GloVe como única representación (A3a, −0,095) |
| B | Siete de sentimiento, tres de interacción con comentarios (máximo, media y Gini de likes), 20 tópicos TF-IDF/SVD, antigüedad y categoría: 32 en total | Sentimiento del clasificador mejorado (B1), 11 variables de formato del título (B2), *embeddings* del título (B3) y de comentarios (B4, B5), y el subconjunto SHAP (B6) |
| Excluidas | Likes y número de comentarios del video, por fuga de información (Avances II, sección 7). | |

La selección se apoyó en tres herramientas: ablación por iteración, que mide el efecto de cada familia de variables frente a la mejor versión vigente; importancia SHAP, que confirma el peso de las variables retenidas; y selección SHAP anidada, que mostró que reducir el conjunto empeora el resultado. La conclusión es que el conjunto de Avances II ya era el adecuado para la etapa B, mientras que en la etapa A la ampliación de variables sí aportó.

## 8. ¿Es Suficiente un Solo Modelo?

Las iteraciones permiten responder la pregunta con evidencia en tres niveles:

- Entre etapas: se requieren al menos dos modelos, porque el sentimiento se define por comentario y el desempeño por video, y porque la regresión de vistas y la clasificación de éxito relativo responden preguntas distintas con algoritmos óptimos diferentes (XGBoost frente a regresión logística).
- Dentro de la etapa B: un solo modelo no es suficiente. El *stacking* (0,793) supera a su mejor componente (0,787) y reduce significativamente el error absoluto. Esto es posible porque los componentes cometen errores parcialmente independientes: los modelos de árboles capturan interacciones no lineales y Ridge aporta una tendencia lineal estable.
- Dentro de la etapa A: un solo modelo sí es suficiente. El *stacking* de cinco clasificadores (0,748) quedó por debajo del SVM híbrido (0,757), porque ese SVM ya integra las representaciones de los demás (TF-IDF, léxico y GloVe) y sus errores están muy correlacionados con los de los componentes, de modo que el meta-modelo no encuentra información nueva que combinar.

La respuesta, por tanto, no es universal: combinar modelos es útil cuando sus errores son diversos y redundante cuando un modelo ya integra todas las fuentes de información.

## 9. Robustez e Incertidumbre del Modelo

### 9.1 Análisis de Sensibilidad

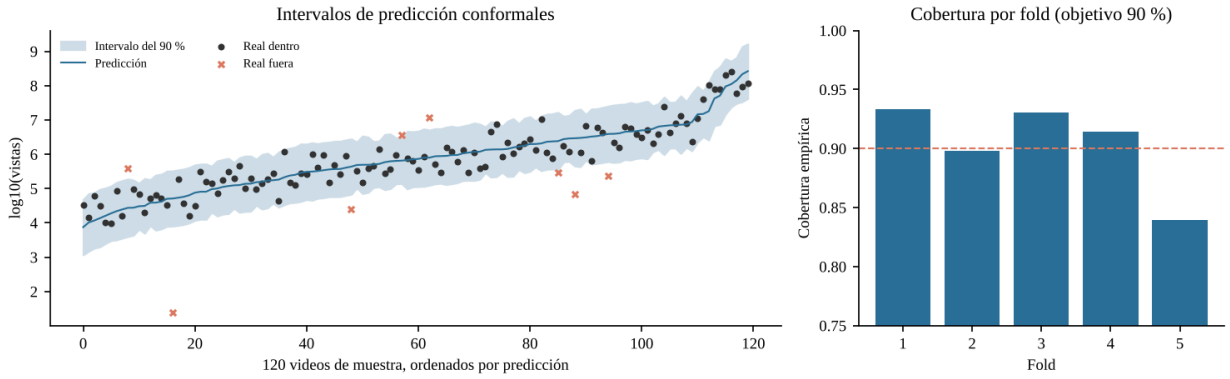
Se ejecutaron dos iteraciones de control para evaluar la dependencia del modelo respecto a sus supuestos. En la primera (B9a) se retiraron las variables de likes de los comentarios, que en parte reflejan el tamaño de la audiencia: el $R^2$ descendió de 0,787 a 0,674, de modo que el modelo conserva capacidad predictiva con solo texto, tópicos, antigüedad y categoría, aunque la interacción con los comentarios es su principal fuente de información. En la segunda (B9b) se predijeron las vistas por día en lugar de las vistas totales: el $R^2$ cayó a 0,547, lo que confirma que una parte importante del desempeño explicado se debe a la acumulación en el tiempo y que la tasa diaria de vistas es un objetivo considerablemente más difícil.

### 9.2 Intervalos de Predicción Conformales

Un modelo consumible por un usuario debe comunicar su incertidumbre. Para ello se implementó predicción conformal dividida (Angelopoulos y Bates, 2021): en cada fold, el 20 % del entrenamiento se reservó para calibrar el cuantil 90 de los residuos absolutos, que define un intervalo alrededor de cada predicción con cobertura garantizada bajo intercambiabilidad (Figura 6).

**Figura 6**

*Intervalos de predicción conformales del 90 % y cobertura empírica por fold*




**Análisis:** la cobertura empírica fue del 90,3 % (entre 83,9 % y 93,3 % según el fold), muy cercana al 90 % nominal, lo que valida el procedimiento. El ancho medio del intervalo es de ±0,78 en escala $\log_{10}$, equivalente a un factor de ×6,1 sobre las vistas: por ejemplo, para una predicción de 100.000 vistas el intervalo va de unas 16.000 a 610.000. Esta amplitud refleja la incertidumbre real del problema y será la información que la API de la entrega final devolverá junto con cada predicción.

## 10. Lecciones de la Iteración y Próximos Pasos

- Las iteraciones guiadas por el análisis de errores (preprocesamiento y contexto) produjeron las mayores ganancias, mientras que el ajuste de hiperparámetros, tanto en malla como bayesiano, no aportó: el modelo estaba limitado por la información y no por su configuración.
- Un mejor clasificador de sentimiento no implica una mejor predicción del alcance, porque el tono de los comentarios tiene una relación débil con las vistas.
- Combinar modelos solo es útil cuando sus errores son diversos, como en la etapa B y no en la etapa A.
- Para la entrega final (semana 10) se expondrán ambas etapas como una API desplegada en la nube que devolverá la predicción, su intervalo conformal y la distribución de sentimiento; se monitoreará la deriva de esa distribución y se usará el registro de MLflow como base del versionamiento de modelos.

## 11. Conclusiones

- Se ejecutaron 23 iteraciones bajo un protocolo común de validación cruzada, validación anidada para todo componente ajustable y registro en MLflow, lo que hace comparables y reproducibles todas las decisiones.
- El clasificador de sentimiento mejoró de 0,708 a 0,757 de F1-macro (IC 95 % de la mejora: 0,041–0,057; McNemar, $p \approx 3{,}5 \cdot 10^{-44}$), con la mayor ganancia en la clase negativa (+0,072).
- En la etapa B ninguna variable nueva superó al conjunto de Avances II y la optimización bayesiana confirmó que los hiperparámetros estaban en la zona óptima; el *stacking* de cuatro modelos elevó el $R^2$ a 0,793 y redujo el error absoluto de forma significativa.
- Las variables de interacción con comentarios y la antigüedad dominan la predicción según SHAP, y sin ellas el $R^2$ desciende a 0,674.
- Los intervalos conformales alcanzan la cobertura nominal (90,3 %) y cuantifican una incertidumbre de un factor de ×6 sobre las vistas, que deberá comunicarse al usuario final.

## 12. Referencias

Akiba, T., Sano, S., Yanase, T., Ohta, T. y Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. En *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 2623–2631). https://doi.org/10.1145/3292500.3330701

Alemán Viteri, S. B. (2021). Análisis de sentimientos para Twitter con Vader y TextBlob. *Revista Odigos, 2*(3), 9–25. https://doi.org/10.35290/ro.v2n3.2021.494

Angelopoulos, A. N. y Bates, S. (2021). *A gentle introduction to conformal prediction and distribution-free uncertainty quantification*. arXiv. https://doi.org/10.48550/arXiv.2107.07511

Chen, T. y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). https://doi.org/10.1145/2939672.2939785

Hutto, C. J. y Gilbert, E. (2014). VADER: A parsimonious rule-based model for sentiment analysis of social media text. En *Proceedings of the Eighth International AAAI Conference on Weblogs and Social Media* (pp. 216–225).

Kreuzberger, D., Kühl, N. y Hirschl, S. (2023). Machine learning operations (MLOps): Overview, definition, and architecture. *IEEE Access, 11*, 31866–31879. https://doi.org/10.1109/ACCESS.2023.3262138

Loria, S. (2020). *TextBlob: Simplified text processing* [Software]. https://textblob.readthedocs.io

Lundberg, S. M. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems 30* (pp. 4765–4774).

Patil, A. (2022). *YouTube statistics* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/advaypatil/youtube-statistics

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M. y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Pennington, J., Socher, R. y Manning, C. D. (2014). GloVe: Global vectors for word representation. En *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing* (pp. 1532–1543). https://doi.org/10.3115/v1/D14-1162

Wolpert, D. H. (1992). Stacked generalization. *Neural Networks, 5*(2), 241–259. https://doi.org/10.1016/S0893-6080(05)80023-1

Zaharia, M., Chen, A., Davidson, A., Ghodsi, A., Hong, S. A., Konwinski, A., Murching, S., Nykodym, T., Ogilvie, P., Parkhe, M., Xie, F. y Zumar, C. (2018). Accelerating the machine learning lifecycle with MLflow. *IEEE Data Engineering Bulletin, 41*(4), 39–45.