UNIVERSIDAD DE CUNDINAMARCA
ESPECIALIZACIÓN EN INTELIGENCIA ARTIFICIAL
PROCESAMIENTO DE LENGUAJE NATURAL
DOCENTE: PAUL ALEXANDER DÍAZ MONTAÑA

INFORME DE PROYECTO: ESTADÍSTICAS DE YOUTUBE – AVANCES III
ITERACIÓN Y MEJORA DEL MODELO DE DESEMPEÑO DE VIDEOS A PARTIR DE SUS COMENTARIOS

ESTUDIANTE: YOHAN NICOLÁS GÓMEZ CASTAÑEDA
CC: 1233903906

FECHA: 18 DE OCTUBRE DE 2026
REPOSITORIO: https://github.com/Nicolas2322/proyecto-estadisticas-youtube

Contenido

1. Introducción 3
2. Respuestas a las Preguntas de la Entrega 3
3. Metodología de Iteración 4
    3.1 Protocolo de Evaluación y Criterio de Adopción 4
    3.2 Herramientas Utilizadas 5
    3.3 Registro de Limpieza y Trazabilidad de los Datos 5
4. Iteraciones de la Etapa A: Clasificación de Sentimiento 7
    4.1 Descripción de las Iteraciones 7
    4.2 Resultados de la Etapa A 8
    4.3 Significancia Estadística de la Mejora 9
    4.4 Iteración con un Modelo de Lenguaje Preentrenado 9
5. Iteraciones de la Etapa B: Desempeño del Video 10
    5.1 Descripción de las Iteraciones 10
    5.2 Resultados de la Etapa B 12
    5.3 Optimización Bayesiana de Hiperparámetros 12
    5.4 Clasificación del Éxito Relativo 13
6. Modelo Seleccionado 13
7. Variables Seleccionadas 15
8. ¿Es Suficiente un Solo Modelo? 15
9. Robustez e Incertidumbre del Modelo 16
    9.1 Análisis de Sensibilidad 16
    9.2 Intervalos de Predicción Conformales 16
10. Lecciones de la Iteración y Próximos Pasos 17
11. Conclusiones 17
12. Referencias 18

Proyecto Estadísticas de YouTube – Avances III: Iteración y Mejora del Modelo

1. Introducción

El presente informe documenta la tercera etapa del proyecto, enfocada en la iteración del modelo y en las herramientas probadas para mejorarlo. En Avances II se estableció una arquitectura de dos etapas: un clasificador de sentimiento por comentario (etapa A), basado en una máquina de soporte vectorial (SVM) lineal con TF-IDF de palabras y caracteres, y un modelo de desempeño por video (etapa B), basado en XGBoost, que estima el logaritmo de las vistas a partir de variables agregadas de los comentarios. Ese punto de partida alcanzó un F1-macro de 0,708 en la etapa A y un R^2 de 0,787 en la etapa B.

En esta etapa se ejecutaron 25 iteraciones, nueve en la etapa A y dieciséis en la etapa B (incluidos los componentes individuales del ensamble y los análisis de robustez e incertidumbre), todas evaluadas con las mismas particiones de validación cruzada y registradas en MLflow como bitácora de experimentos, siguiendo los principios de seguimiento y reproducibilidad de MLOps descritos por Kreuzberger et al. (2023). En la etapa A, la combinación de un preprocesamiento orientado a redes sociales, variables léxicas y de contexto, *embeddings* GloVe entrenados con tuits y un ajuste anidado de umbrales elevó el F1-macro a 0,757 (+0,049; IC 95 %: 0,041–0,057), con la mayor ganancia en la clase negativa (+0,072). Una iteración final con un modelo de lenguaje preentrenado, RoBERTa entrenado con tuits y ajustado con las etiquetas del proyecto en una GPU, elevó el F1-macro a 0,900 ± 0,005, superior al mejor modelo clásico en los cinco folds. En la etapa B, ninguna variable nueva superó a las existentes y la optimización bayesiana no mejoró los hiperparámetros, pero un ensamble por *stacking* de cuatro modelos elevó el R^2 a 0,793 y redujo el error absoluto de forma significativa (prueba de Wilcoxon, $p \approx 2 \cdot 10^{-9}$). Se incorporaron además intervalos de predicción conformales con una cobertura empírica del 90,3 %.

2. Respuestas a las Preguntas de la Entrega

La Tabla 1 sintetiza la respuesta a cada pregunta planteada para la semana 9; las secciones siguientes desarrollan cada punto.

Tabla 1

Respuestas a las preguntas de la entrega

Pregunta	Respuesta
¿Qué iteraciones se realizaron y qué mejoraron?	Nueve iteraciones en la etapa A (preprocesamiento, variables léxicas y de contexto, *embeddings* GloVe, umbrales por clase, *stacking* y un *transformer* RoBERTa sin ajuste y con ajuste fino) y dieciséis en la etapa B (sentimiento mejorado, variables y *embeddings* del título, *embeddings* de comentarios, selección por SHAP, Optuna, ensambles y análisis de robustez). La etapa A mejoró 0,192 de F1-macro (0,049 con modelos clásicos y 0,143 adicionales con el *transformer*); la etapa B, 0,006 de R^2 y 3,3 % de error absoluto (secciones 4 y 5).
¿Cuál fue el modelo seleccionado?	Etapa A: RoBERTa-Twitter (*twitter-roberta-base-sentiment-latest*) con ajuste fino sobre las etiquetas del proyecto; como alternativa ligera para CPU se conserva el SVM lineal híbrido con umbrales ajustados de forma anidada. Etapa B: *stacking* de XGBoost, HistGradientBoosting, Random Forest y Ridge con meta-modelo RidgeCV. Éxito relativo: regresión logística (sección 6).
¿Cuál fue su desempeño y bajo qué métricas?	Etapa A: F1-macro 0,900 ± 0,005 y exactitud 0,927 (SVM híbrido: 0,757 y 0,820). Etapa B: R^2 0,793 ± 0,016; MAE 0,347 en $\log_{10}$ (factor ×2,22); ρ de Spearman 0,893; intervalos del 90 % con cobertura del 90,3 %. Éxito relativo: ROC-AUC 0,879; puntuación de Brier 0,141.
¿Cuántos modelos se probaron?	Veinticinco iteraciones con diez algoritmos distintos (SVM lineal, regresión logística, Complement NB, *transformer* RoBERTa, XGBoost, HistGradientBoosting, Random Forest, Ridge y los ensambles por promedio y *stacking*), más 125 ensayos de optimización bayesiana (25 por cada uno de los cinco folds externos). Todas las corridas se registraron en MLflow.
¿Qué herramientas se usaron para determinar el modelo?	Validación cruzada con particiones fijas, validación cruzada anidada, Hugging Face Transformers y PyTorch en GPU, Optuna (TPE), SHAP, prueba de McNemar, *bootstrap*, prueba de Wilcoxon, predicción conformal y MLflow (Tabla 2), además de un registro automático de limpieza con respaldo de los registros retirados (Tabla 3).
¿Es suficiente un solo modelo?	No. Además de la arquitectura de dos etapas, en la etapa B el ensamble supera a todos sus componentes individuales; en cambio, en la etapa A el *stacking* no mejoró al SVM híbrido y el *transformer* por sí solo supera a cualquier combinación de modelos clásicos. La respuesta depende de la diversidad de errores entre modelos (sección 8).
¿Qué variables se seleccionaron para predecir?	Etapa A: el texto completo del comentario, tokenizado en subpalabras para RoBERTa; el SVM alternativo usa n-gramas de palabras y caracteres, 11 variables léxicas, la categoría y 100 dimensiones GloVe. Etapa B: las 32 variables de Avances II (sentimiento, interacción con comentarios, 20 tópicos, antigüedad y categoría); las 4 familias de variables nuevas se descartaron por no aportar (sección 7).

3. Metodología de Iteración

3.1 Protocolo de Evaluación y Criterio de Adopción

Para que las iteraciones fueran comparables, todas se evaluaron con las mismas cinco particiones de validación cruzada con semilla fija (42): estratificadas por clase en la etapa A (18.139 comentarios) y aleatorias en la etapa B (1.867 videos). La métrica principal fue el F1-macro en la

etapa A, por el desbalance de clases, y el R^2 sobre $\log_{10}$(vistas) en la etapa B. Cada iteración modificó un solo aspecto respecto a la mejor versión vigente; se adoptó cuando mejoró la métrica principal media, y las diferencias menores a 0,002 se trataron como empates, que solo se adoptaron si no añadían complejidad al modelo. Cualquier componente con hiperparámetros propios (umbrales, Optuna, meta-modelos) se ajustó dentro de cada partición de entrenamiento, mediante validación cruzada anidada, para evitar estimaciones optimistas.

3.2 Herramientas Utilizadas

La Tabla 2 resume las herramientas incorporadas en esta etapa y la función que cumplieron.

Tabla 2

Herramientas utilizadas en la iteración del modelo

Herramienta	Uso en el proyecto	Iteraciones
emoji y expresiones regulares	Conversión de emojis a texto, reducción de alargamientos y marcado de negación	A1
VADER y TextBlob	Variables léxicas de polaridad, intensidad y subjetividad	A2
Gensim y GloVe Twitter	*Embeddings* de 100 dimensiones preentrenados con 2.000 millones de tuits (Pennington et al., 2014)	A3, B3, B4
Hugging Face Transformers y PyTorch	Inferencia y ajuste fino de RoBERTa-Twitter (Loureiro et al., 2022) en una GPU T4 de Google Colab, con los mismos 5 folds (Wolf et al., 2020)	A6
scikit-learn	Canalizaciones, validación cruzada, *stacking* y modelos lineales y de árboles (Pedregosa et al., 2011)	Todas
XGBoost	Modelo de *gradient boosting* de la etapa B (Chen y Guestrin, 2016)	B0–B9
Optuna	Optimización bayesiana de hiperparámetros con el muestreador TPE (Akiba et al., 2019)	B7
SHAP	Explicación del modelo y selección de variables por valores de Shapley (Lundberg y Lee, 2017)	B6, modelo final
Predicción conformal	Intervalos de predicción con cobertura garantizada (Angelopoulos y Bates, 2021); implementación propia	B10
MLflow	Registro de parámetros y métricas de cada iteración en una base SQLite (Zaharia et al., 2018)	Todas
SciPy	Pruebas de McNemar y de Wilcoxon e intervalos *bootstrap*	Comparación final

3.3 Registro de Limpieza y Trazabilidad de los Datos

Antes de iterar sobre los modelos se documentó cada transformación aplicada a los datos crudos, siguiendo la fase de preparación de la metodología CRISP-DM (Chapman et al., 2000). El objetivo es triple: que cualquier persona pueda verificar cuántos registros se modificaron y por qué, que ningún valor faltante se elimine sin una regla que lo justifique y que cualquier paso pueda revertirse. Para ello se generó un registro automático en formato JSON con los conteos

antes y después de cada paso y la huella SHA-256 de los archivos originales, que identifica sin ambigüedad la versión exacta del conjunto usado. Los registros retirados no se borran: se conservan en archivos CSV de respaldo dentro del repositorio, de modo que revertir un paso consiste en reincorporarlos, sin necesidad de copias completas del conjunto. La Tabla 3 resume el registro.

Tabla 3

Registro de limpieza de los datos con conteos, criterio aplicado y respaldo

Paso	Antes	Después	Criterio y decisión	Respaldo
Videos: tipos y estandarización	1.881	1.881	Fechas convertidas a tipo fecha (0 fallos), contadores numéricos y categorías normalizadas en minúscula (41 categorías, ninguna inconsistente).	—
Videos: mismo identificador repetido	1.881	1.869	12 videos aparecen dos veces y ninguno es un duplicado exacto. En 3 solo cambia la palabra clave de búsqueda; en 6 los contadores difieren menos del 5 %, porque son el mismo video capturado en momentos distintos; en 3 las vistas difieren de forma importante. Se conserva la primera aparición.	retirados_videos_duplicados.csv
Videos: contadores ocultos (−1)	1.869	1.869	6 videos con likes ocultos y 2 con comentarios ocultos. No se eliminan: se recategorizan como «contador oculto» (faltante) y el modelo los imputa con la mediana.	—
Videos: sin variable objetivo	1.869	1.867	2 videos sin número de vistas. Sin el valor a predecir no pueden usarse para entrenar ni evaluar.	retirados_videos_sin_vistas.csv
Comentarios: sin texto	18.409	18.408	1 comentario vacío, que no aporta información al análisis de sentimiento.	retirados_comentarios_sin_texto.csv
Comentarios: repetidos en el mismo video	18.408	18.159	249 repeticiones, de las cuales 148 son copias exactas. En 93 grupos solo difieren los likes y en ninguno la etiqueta: es el mismo comentario capturado en momentos distintos.	retirados_comentarios_duplicados.csv
Comentarios: de videos retirados	18.159	18.139	20 comentarios de los 2 videos sin variable objetivo.	retirados_comentarios_sin_video.csv

Nota. Huellas SHA-256 de los archivos originales: videos-stats.csv 09b52f4a…f930a; comments.csv bc78f5fb…f651b (valores completos en registro_limpieza.json).

Dos decisiones merecen justificación. La primera es que los contadores ocultos no se eliminaron: el valor −1 es la convención de YouTube para un contador deshabilitado por el creador, no un cero ni un error, y borrar esos videos habría sesgado la muestra contra los creadores que ocultan sus métricas. La segunda es que los duplicados se analizaron antes de eliminarse: ninguno de los videos repetidos era una copia exacta, por lo que se distinguieron los duplicados lógicos (mismo video bajo otra búsqueda o capturado minutos después) de los tres casos con vistas contradictorias, que se documentan como una limitación de la fuente. En todos los casos los registros retirados quedan disponibles para revertir la decisión si un análisis posterior lo requiere.

4. Iteraciones de la Etapa A: Clasificación de Sentimiento

4.1 Descripción de las Iteraciones

El análisis de errores de Avances II mostró que la debilidad principal del clasificador era la clase negativa (F1 = 0,59), con un 22 % de comentarios negativos confundidos con neutrales. Las iteraciones se diseñaron para atacar las causas probables de esa confusión: información perdida en la limpieza, ausencia de conocimiento léxico previo, falta de contexto temático y vocabulario poco frecuente. La Tabla 4 describe cada iteración y su resultado.

Tabla 4

Iteraciones de la etapa A y decisión adoptada

Iteración	Cambio y justificación	F1-macro	Δ	Decisión
A0 Base	SVM lineal con TF-IDF de palabras (1-2 gramas) y caracteres (2-5 gramas), C = 0,1, ajustado en Avances II.	0,708 ± 0,011	–	Punto de partida
A1 Preprocesamiento	Emojis convertidos a palabras (el emoji de risa con lágrimas pasa a *face_with_tears_of_joy*), alargamientos reducidos (*sooo → soo*), contracciones negativas expandidas y marcado de negación en una ventana de tres palabras (*not good → not NEG_good*). La limpieza anterior eliminaba los emojis y no distinguía «good» de «not good».	0,723 ± 0,011	+0,015	Adoptada
A2 Híbrido léxico y contexto	Se añadieron 11 variables léxicas (VADER, TextBlob, longitud, signos, emojis, proporción de mayúsculas) y la categoría del video. El léxico aporta conocimiento previo de polaridad y la categoría ajusta la tasa base de negatividad, que varía del 2 % al 55 % según el tema (Avances II, análisis 5).	0,745 ± 0,009	+0,022	Adoptada
A3a GloVe solo	Promedio de *embeddings* GloVe Twitter con regresión logística, como prueba aislada de la representación densa.	0,650 ± 0,006	−0,095	Descartada como modelo aislado
A3b + GloVe (híbrido)	Las 100 dimensiones GloVe se añadieron al modelo A2. Los *embeddings* asignan representaciones cercanas a palabras sinónimas o mal escritas que no comparten n-gramas.	0,755 ± 0,007	+0,010	Adoptada
A4 Umbrales por clase	Sesgos aditivos por clase sobre la función de decisión, elegidos dentro de cada partición de entrenamiento mediante validación cruzada interna de tres folds, para maximizar el F1-macro.	0,757 ± 0,008	+0,002	Adoptada: mejor modelo clásico (empate sin costo de inferencia)

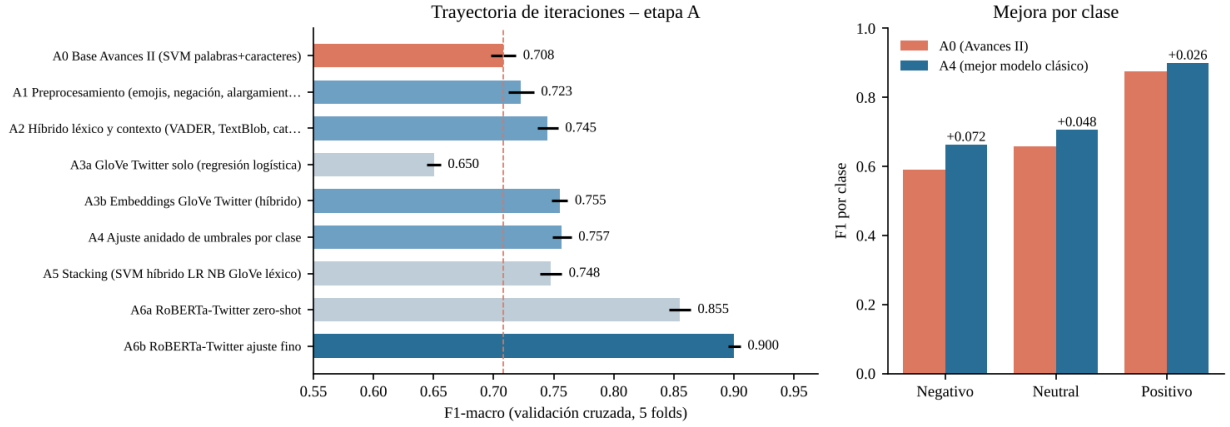
Iteración	Cambio y justificación	F1-macro	Δ	Decisión
A5 *Stacking*	Meta-modelo de regresión logística sobre cinco clasificadores base: SVM híbrido, regresión logística, Complement NB, GloVe y léxico.	0,748 ± 0,009	−0,009	Descartada
A6a RoBERTa-Twitter sin ajuste	*Transformer* RoBERTa preentrenado con unos 124 millones de tuits y ya entrenado para sentimiento en tres clases, aplicado sin reentrenar (*zero-shot*). Prueba si el conocimiento previo del lenguaje supera a los modelos entrenados con el corpus.	0,855 ± 0,010	+0,098	Superada por A6b
A6b RoBERTa-Twitter con ajuste fino	El mismo modelo reentrenado dos épocas con las etiquetas del proyecto en cada fold (tasa $2 \cdot 10^{-5}$, lote 32, pesos de clase balanceados), en una GPU T4.	**0,900 ± 0,005**	+0,045	**Adoptada: modelo final**

Nota. F1-macro: media ± desviación estándar en cinco folds estratificados. Δ = cambio frente a la mejor iteración vigente. El valor de A0 (0,708) difiere levemente del 0,710 de Avances II porque en este informe se usa el C = 0,1 hallado en la búsqueda en malla, en lugar del C = 0,3 inicial. La cobertura de GloVe sobre el vocabulario de los comentarios fue del 91,9 %. El Δ de A6a se calcula frente a A4 y el de A6b frente a A6a. Exactitud de A6a: 0,892; de A6b: 0,927.

4.2 Resultados de la Etapa A

Figura 1

Trayectoria de las iteraciones de la etapa A y mejora del F1 por clase

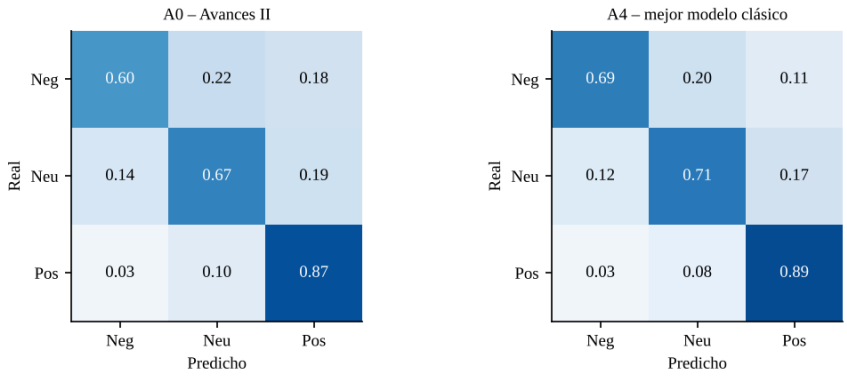


Análisis: las mayores ganancias provinieron de iteraciones guiadas por el análisis de errores. El preprocesamiento (+0,015) recuperó información que la limpieza anterior destruía (emojis y negaciones), y la incorporación del léxico y la categoría (+0,022) fue el mayor salto individual, lo que confirma que el contexto temático hallado en Avances II tiene valor predictivo para el sentimiento. GloVe por sí solo rinde menos que el TF-IDF (0,650), pero combinado aporta +0,010, ya que ambos tipos de representación son complementarios. El ajuste de umbrales

produjo un empate técnico (+0,002, inferior a la desviación entre folds); se conservó porque solo suma un sesgo constante a la predicción. Entre los modelos clásicos, la mejora más relevante se dio en la clase negativa: su F1 pasó de 0,591 a 0,664 (+0,072) y su sensibilidad de 0,598 a 0,686. El salto más grande de toda la etapa lo produjo el *transformer*, analizado en la sección 4.4.

Figura 2

Matrices de confusión normalizadas del modelo base y del mejor modelo clásico



Análisis: la proporción de comentarios negativos clasificados como positivos se redujo del 17,8 % al 11,2 %, y la de negativos confundidos con neutrales del 22,4 % al 20,2 %. La exactitud global subió de 0,782 a 0,820. La confusión residual entre negativo y neutral se concentra en críticas expresadas sin palabras negativas, como «Imagine losing the cursor on that screen and trying to find it» (acompañado de un emoji de calavera) o «The price of the road-going Kawasaki really tells how overpriced the push bikes are», cuya interpretación requiere ironía o conocimiento del mundo que los modelos de bolsa de palabras no capturan. Esta limitación motivó la iteración con un modelo de lenguaje preentrenado.

4.3 Significancia Estadística de la Mejora

Para comprobar que la mejora no se debe al azar, se compararon las predicciones fuera de fold del modelo base y del final sobre los 18.139 comentarios. La prueba de McNemar indica que el modelo final acierta en 1.558 comentarios en los que el base falla, frente a 870 en el caso contrario ($\chi^2 = 194{,}4$; $p \approx 3{,}5 \cdot 10^{-44}$). Un *bootstrap* de 1.000 remuestreos ubica la mejora del F1-macro entre 0,041 y 0,057 con un 95 % de confianza, por lo que la ganancia es estadísticamente sólida.

4.4 Iteración con un Modelo de Lenguaje Preentrenado

El análisis de errores mostró que los fallos residuales de los modelos clásicos se deben a ironía, contexto y conocimiento del mundo, aspectos que una representación por bolsa de palabras no puede capturar. Por ello se evaluó un *transformer*: RoBERTa (Liu et al., 2019) en su versión

twitter-roberta-base-sentiment-latest, preentrenado con unos 124 millones de tuits y especializado en sentimiento de tres clases (Loureiro et al., 2022). Dado que el entorno de trabajo no dispone de GPU, el experimento se ejecutó en Google Colab con una GPU NVIDIA T4 y los mismos cinco folds del resto del informe, de modo que sus resultados son directamente comparables. Se probaron dos variantes: sin reentrenar (A6a) y con ajuste fino de dos épocas por fold (A6b), que tomó 16 minutos en total.

Tabla 5

F1-macro por fold del mejor modelo clásico y de las dos variantes del transformer

Modelo	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5	Media
A4 SVM híbrido con umbrales	0,756	0,770	0,750	0,759	0,749	0,757
A6a RoBERTa-Twitter sin ajuste	0,863	0,849	0,846	0,868	0,848	0,855
A6b RoBERTa-Twitter con ajuste fino	**0,904**	**0,904**	**0,896**	**0,905**	**0,892**	**0,900**

Nota. Comparación pareada por fold (prueba t, 4 grados de libertad): A6b frente a A4, +0,143 ($t = 55{,}1$; $p \approx 6{,}5 \cdot 10^{-7}$); A6a frente a A4, +0,098 ($p \approx 5{,}5 \cdot 10^{-5}$); A6b frente a A6a, +0,045 ($p \approx 1{,}4 \cdot 10^{-4}$).

El *transformer* supera al mejor modelo clásico en los cinco folds, con una diferencia de entre 0,133 y 0,148 puntos de F1-macro, y el ajuste fino añade 0,045 sobre la versión sin reentrenar. La ganancia es coherente con la naturaleza de los errores: RoBERTa representa cada palabra según su contexto, por lo que distingue «not bad» de «bad» o una crítica irónica de un elogio, algo que el SVM solo aproximaba con reglas de negación.

Se aplica además una lectura crítica del resultado. Que el modelo sin reentrenar ya alcance una exactitud de 0,892 sobre etiquetas que no conoce es una concordancia inusualmente alta para un problema de sentimiento, en el que el acuerdo entre anotadores humanos suele ser menor. El conjunto de datos no documenta cómo se asignaron las etiquetas, por lo que es plausible que se hayan generado con un clasificador automático similar. Si fuera así, parte de la ventaja del *transformer* reflejaría su parecido con el procedimiento de etiquetado más que una mejor comprensión del sentimiento real. Esta hipótesis refuerza la auditoría de etiquetas propuesta en Avances II (re-etiquetar a mano una muestra y medir el acuerdo) como paso previo a la entrega final.

5. Iteraciones de la Etapa B: Desempeño del Video

5.1 Descripción de las Iteraciones

Las iteraciones de la etapa B exploraron cuatro frentes: mejores variables de texto, nuevas fuentes de información, ajuste de hiperparámetros y combinación de modelos. La Tabla 6 resume cada iteración.

Tabla 6

Iteraciones de la etapa B y decisión adoptada

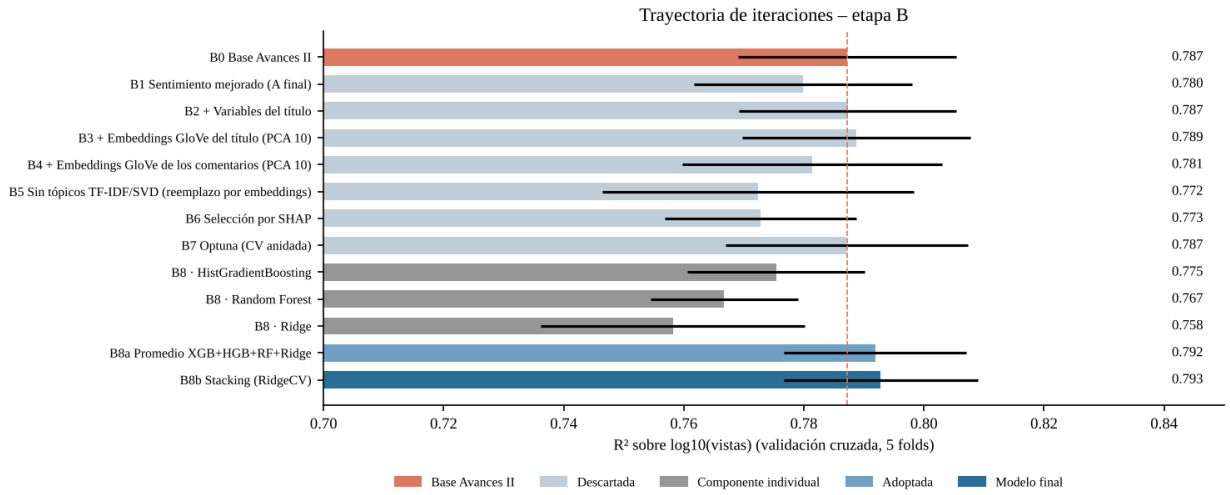
Iteración	Cambio y justificación	R^2	MAE	Decisión
B0 Base	XGBoost con las 32 variables de Avances II.	0,787 ± 0,018	0,359	Punto de partida
B1 Sentimiento mejorado	Proporciones de sentimiento calculadas con el clasificador final de la etapa A.	0,780 ± 0,018	0,362	Descartada (−0,007)
B2 Variables del título	Once variables de formato del título: longitud, mayúsculas, dígitos, signos, separadores, *#shorts* y «official». El título está disponible desde la publicación.	0,787 ± 0,018	0,360	Descartada (+0,000)
B3 *Embeddings* del título	Promedio GloVe del título reducido con PCA a 10 componentes.	0,789 ± 0,019	0,357	Descartada (empate, +0,002)
B4 *Embeddings* de comentarios	Promedio GloVe de todos los comentarios del video (PCA 10).	0,781 ± 0,022	0,364	Descartada (−0,006)
B5 *Embeddings* en lugar de tópicos	Sustitución de los 20 tópicos TF-IDF/SVD por los *embeddings* de comentarios.	0,772 ± 0,026	0,373	Descartada (−0,015)
B6 Selección por SHAP	En cada fold se conservaron las variables que suman el 95 % de la importancia SHAP (≈ 36 de 72 columnas).	0,773 ± 0,016	0,369	Descartada (−0,014)
B7 Optuna anidado	Optimización bayesiana de ocho hiperparámetros: 25 ensayos con validación interna de tres folds en cada uno de los cinco folds externos.	0,787 ± 0,020	0,360	Descartada (−0,000)
B8a Ensamble por promedio	Promedio de XGBoost, HistGradientBoosting, Random Forest y Ridge.	0,792 ± 0,015	0,349	Adoptada (+0,005)
B8b *Stacking*	Los mismos cuatro modelos combinados por un meta-modelo RidgeCV entrenado con predicciones internas de cinco folds.	**0,793 ± 0,016**	**0,347**	**Adoptada: modelo final**

Nota. R^2 y MAE sobre $\log_{10}$(vistas), media de cinco folds. Componentes individuales con las mismas variables: HistGradientBoosting 0,775; Random Forest 0,767; Ridge 0,758. Las iteraciones B9 y B10 (robustez e incertidumbre) se presentan en la sección 9.

5.2 Resultados de la Etapa B

Figura 3

Trayectoria de las iteraciones de la etapa B



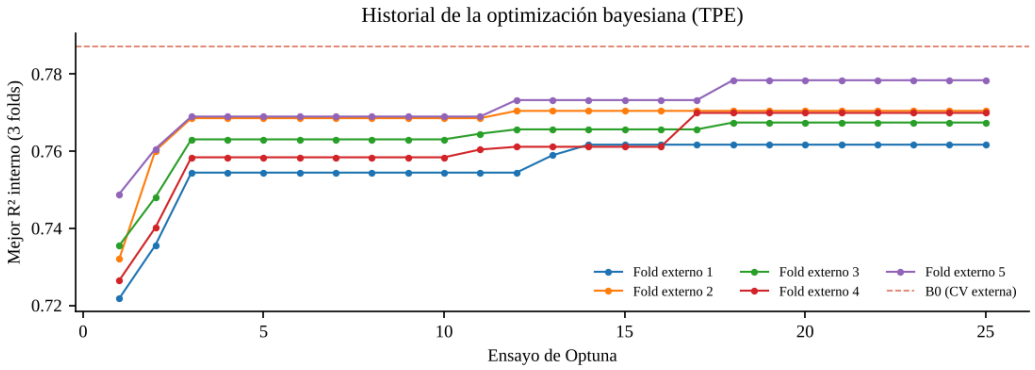
Análisis: el resultado más informativo de esta etapa es negativo: ninguna de las cinco iteraciones de variables superó al conjunto de Avances II. Mejorar el clasificador de sentimiento (B1) incluso empeoró levemente la predicción, lo que refuerza el hallazgo de Avances II de que el tono de los comentarios explica poco del alcance. El título, aunque está disponible desde la publicación, no añade información a la que ya contienen los comentarios y la categoría. Los *embeddings* densos de comentarios rinden menos que los tópicos TF-IDF/SVD, que capturan mejor los temas concretos de cada nicho. La selección por SHAP también empeoró el resultado, ya que muchas variables con baja importancia individual aportan en conjunto. En cambio, combinar modelos sí mejoró: los cuatro algoritmos cometen errores distintos y su ensamble supera al mejor de ellos.

5.3 Optimización Bayesiana de Hiperparámetros

La búsqueda en malla de Avances II exploró una región limitada del espacio de hiperparámetros. Para descartar que existiera una configuración mejor fuera de ella, se aplicó Optuna con el muestreador TPE sobre ocho hiperparámetros de XGBoost: número de árboles, tasa de aprendizaje, profundidad, peso mínimo por hoja, submuestreo de filas y columnas, y regularización L1 y L2. La búsqueda se anidó: en cada fold externo se optimizó con una validación interna de tres folds y el modelo resultante se evaluó en el fold externo, que no participó en la búsqueda (Figura 4).

Figura 4

Historial de la optimización bayesiana en cada fold externo



Análisis: la mejor configuración se encuentra entre los ensayos 12 y 18, y a partir del ensayo 15 la mejora interna es inferior a 0,009; la optimización produce un R^2 externo de 0,787, idéntico al de los hiperparámetros de Avances II. Las configuraciones elegidas son coherentes entre folds (profundidad 5, tasa de aprendizaje ≈ 0,035, alrededor de 400 árboles, submuestreo de columnas ≈ 0,56) y distintas de las iniciales (profundidad 6, tasa 0,06, 800 árboles), lo que indica una superficie de respuesta plana con varias configuraciones equivalentes. Se concluye que el desempeño de XGBoost está limitado por la información disponible y no por los hiperparámetros, por lo que el esfuerzo de mejora debía dirigirse a la combinación de modelos.

5.4 Clasificación del Éxito Relativo

Para la tarea complementaria, que determina si un video supera la mediana de vistas de su categoría, se compararon la regresión logística (C = 100, ajustada en Avances II) y un clasificador XGBoost con las variables finales. La regresión logística obtuvo un ROC-AUC de 0,879 ± 0,004 y una puntuación de Brier de 0,141, frente a 0,857 ± 0,008 y 0,158 de XGBoost. Se mantiene la regresión logística: discrimina mejor, sus probabilidades están mejor calibradas (menor Brier) y es más estable entre folds.

6. Modelo Seleccionado

El modelo resultante de la iteración conserva la arquitectura de dos etapas y modifica sus componentes:

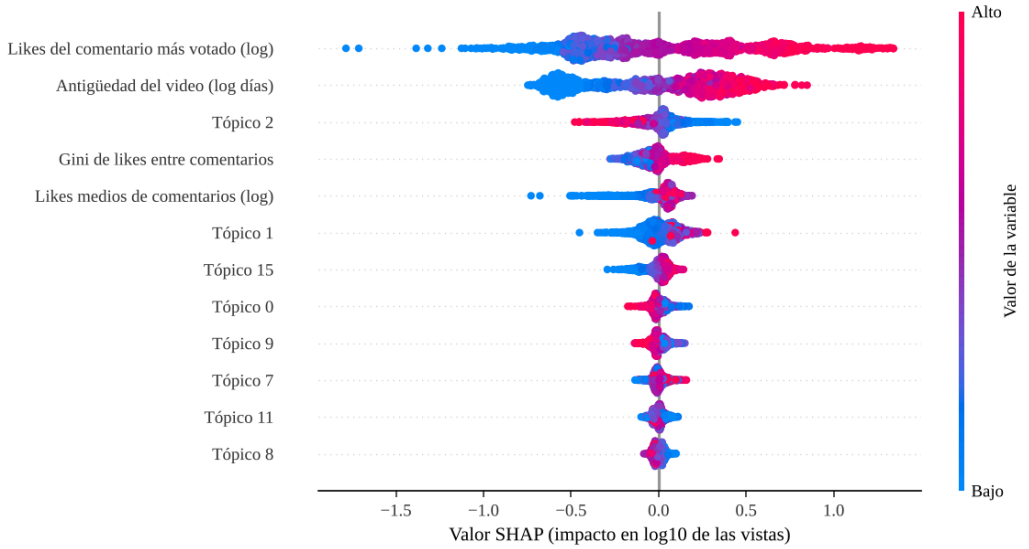
- Etapa A: RoBERTa-Twitter con ajuste fino (125 millones de parámetros, dos épocas, tasa de aprendizaje $2 \cdot 10^{-5}$). Desempeño: F1-macro 0,900; exactitud 0,927. Como alternativa para un despliegue sin GPU se conserva el SVM lineal híbrido (C = 0,1) sobre TF-IDF de palabras y caracteres del texto normalizado, 11 variables léxicas, la categoría y las 100 dimensiones GloVe Twitter, con sesgos por clase ajustados de forma anidada (F1-macro 0,757; exactitud 0,820).

- Etapa B: *stacking* de XGBoost, HistGradientBoosting, Random Forest y Ridge sobre las 32 variables de Avances II, combinados por un meta-modelo RidgeCV. Desempeño: R^2 0,793; MAE 0,347 (factor ×2,22); ρ de Spearman 0,893.
- Éxito relativo: regresión logística (C = 100) con ROC-AUC de 0,879.

La justificación de cada elección es empírica: es la mejor configuración bajo el mismo protocolo de evaluación y su ventaja frente a la base es estadísticamente significativa (prueba t pareada por fold y McNemar en la etapa A; Wilcoxon sobre los errores absolutos en la etapa B, $p \approx 2{,}2 \cdot 10^{-9}$, con mejora en cuatro de cinco folds). En cuanto al costo, el SVM y el ensamble de la etapa B responden en milisegundos en CPU, mientras que RoBERTa requiere más recursos: en GPU clasificó los 18.139 comentarios en 32 segundos, y en CPU será más lento, por lo que la entrega final medirá su latencia y decidirá entre ambos clasificadores según ese resultado. La Figura 5 explica las predicciones del componente XGBoost mediante valores SHAP.

Figura 5

Valores SHAP de las doce variables más influyentes en el componente XGBoost



Análisis: cada punto es un video y su posición horizontal indica cuánto eleva o reduce la predicción de $\log_{10}$(vistas). Los likes del comentario más votado son la variable más influyente (impacto medio de 0,43 órdenes de magnitud): valores altos (rojo) elevan la predicción hasta en un orden de magnitud. Le sigue la antigüedad (0,35), con el patrón esperado de mayor acumulación de vistas en videos más antiguos. El Gini de los likes muestra que una conversación dominada por un comentario destacado se asocia a más vistas, y algunos tópicos de texto (2, 1 y 15) aportan efectos temáticos específicos. Las variables de sentimiento no aparecen entre las doce primeras, lo que es coherente con el resultado de la iteración B1.

7. Variables Seleccionadas

La Tabla 7 resume las variables que conforman el modelo final y las que se evaluaron sin ser incorporadas.

Tabla 7

Variables del modelo final y variables evaluadas sin ser incorporadas

Etapa	Variables incorporadas	Evaluadas y no incorporadas
A	Modelo final: texto completo del comentario tokenizado en subpalabras por RoBERTa. Alternativa en CPU: TF-IDF de palabras (1-2 gramas) y caracteres (2-5 gramas) del texto normalizado, 11 variables léxicas, categoría y 100 dimensiones GloVe Twitter	GloVe como única representación (A3a, −0,095)
B	Siete de sentimiento, tres de interacción con comentarios (máximo, media y Gini de likes), 20 tópicos TF-IDF/SVD, antigüedad y categoría: 32 en total	Sentimiento del clasificador mejorado (B1), 11 variables de formato del título (B2), *embeddings* del título (B3) y de comentarios (B4, B5), y el subconjunto SHAP (B6)
Excluidas	Likes y número de comentarios del video, por fuga de información (Avances II, sección 7).	

La selección se apoyó en tres herramientas: ablación por iteración, que mide el efecto de cada familia de variables frente a la mejor versión vigente; importancia SHAP, que confirma el peso de las variables retenidas; y selección SHAP anidada, que mostró que reducir el conjunto empeora el resultado. La conclusión es que el conjunto de Avances II ya era el adecuado para la etapa B, mientras que en la etapa A la ampliación de variables sí aportó.

8. ¿Es Suficiente un Solo Modelo?

Las iteraciones permiten responder la pregunta con evidencia en tres niveles:

- Entre etapas: se requieren al menos dos modelos, porque el sentimiento se define por comentario y el desempeño por video, y porque la regresión de vistas y la clasificación de éxito relativo responden preguntas distintas con algoritmos óptimos diferentes (XGBoost frente a regresión logística).
- Dentro de la etapa B: un solo modelo no es suficiente. El *stacking* (0,793) supera a su mejor componente (0,787) y reduce significativamente el error absoluto. Esto es posible porque los componentes cometen errores parcialmente independientes: los modelos de árboles capturan interacciones no lineales y Ridge aporta una tendencia lineal estable.
- Dentro de la etapa A: un solo modelo sí es suficiente para la predicción. El *stacking* de cinco clasificadores clásicos (0,748) quedó por debajo del SVM híbrido (0,757), porque ese SVM ya integra las representaciones de los demás y sus errores están muy correlacionados con los de los componentes. A su vez, el *transformer* por sí solo

(0,900) supera ampliamente a cualquier combinación de modelos clásicos. Desde el punto de vista operativo, sin embargo, conviene mantener dos modelos: RoBERTa como principal y el SVM como respaldo para un despliegue en CPU o ante una falla del servicio principal.

La respuesta, por tanto, no es universal: combinar modelos es útil cuando sus errores son diversos y redundante cuando un modelo ya integra todas las fuentes de información.

9. Robustez e Incertidumbre del Modelo

9.1 Análisis de Sensibilidad

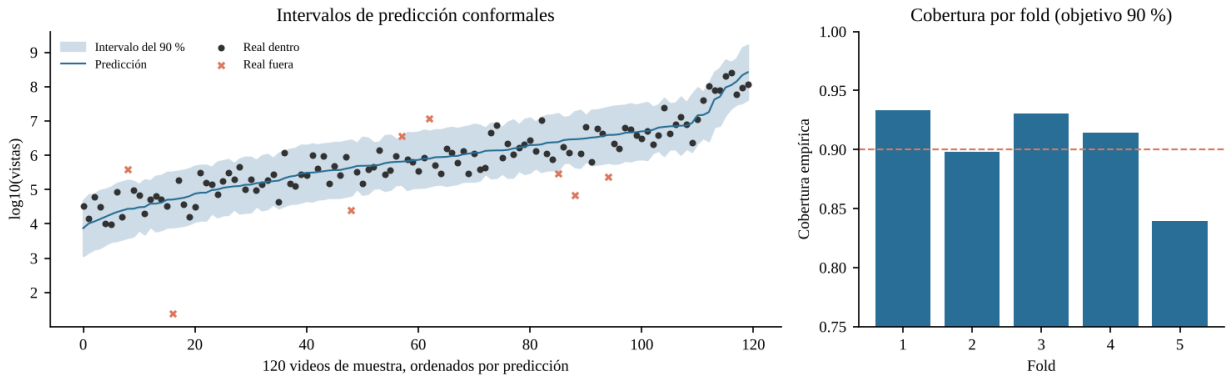
Se ejecutaron dos iteraciones de control para evaluar la dependencia del modelo respecto a sus supuestos. En la primera (B9a) se retiraron las variables de likes de los comentarios, que en parte reflejan el tamaño de la audiencia: el R^2 descendió de 0,787 a 0,674, de modo que el modelo conserva capacidad predictiva con solo texto, tópicos, antigüedad y categoría, aunque la interacción con los comentarios es su principal fuente de información. En la segunda (B9b) se predijeron las vistas por día en lugar de las vistas totales: el R^2 cayó a 0,547, lo que confirma que una parte importante del desempeño explicado se debe a la acumulación en el tiempo y que la tasa diaria de vistas es un objetivo considerablemente más difícil.

9.2 Intervalos de Predicción Conformales

Un modelo consumible por un usuario debe comunicar su incertidumbre. Para ello se implementó predicción conformal dividida (Angelopoulos y Bates, 2021): en cada fold, el 20 % del entrenamiento se reservó para calibrar el cuantil 90 de los residuos absolutos, que define un intervalo alrededor de cada predicción con cobertura garantizada bajo intercambiabilidad (Figura 6).

Figura 6

Intervalos de predicción conformales del 90 % y cobertura empírica por fold



Análisis: la cobertura empírica fue del 90,3 % (entre 83,9 % y 93,3 % según el fold), muy cercana al 90 % nominal, lo que valida el procedimiento. El ancho medio del intervalo es de ±0,78 en escala $\log_{10}$, equivalente a un factor de ×6,1 sobre las vistas: por ejemplo, para una predicción de 100.000 vistas el intervalo va de unas 16.000 a 610.000. Esta amplitud refleja la incertidumbre real del problema y será la información que la API de la entrega final devolverá junto con cada predicción.

10. Lecciones de la Iteración y Próximos Pasos

- Las iteraciones guiadas por el análisis de errores (preprocesamiento y contexto) produjeron las mayores ganancias, mientras que el ajuste de hiperparámetros, tanto en malla como bayesiano, no aportó: el modelo estaba limitado por la información y no por su configuración.
- Los modelos de lenguaje preentrenados resolvieron lo que la ingeniería de variables no pudo: el *transformer* superó en 0,143 de F1-macro al mejor modelo clásico, pero su resultado debe leerse con cautela mientras no se audite el origen de las etiquetas.
- Un mejor clasificador de sentimiento no implica una mejor predicción del alcance, porque el tono de los comentarios tiene una relación débil con las vistas.
- Combinar modelos solo es útil cuando sus errores son diversos, como en la etapa B y no en la etapa A.
- Para la entrega final (semana 10) se expondrán ambas etapas como una API desplegada en la nube que devolverá la predicción, su intervalo conformal y la distribución de sentimiento; se monitoreará la deriva de esa distribución y se usará el registro de MLflow como base del versionamiento de modelos.

11. Conclusiones

- La preparación de los datos quedó documentada en un registro automático con conteos antes y después de cada paso, huellas SHA-256 de los archivos originales y respaldo de los 296 registros retirados, lo que permite auditar y revertir cada decisión.
- Se ejecutaron 25 iteraciones bajo un protocolo común de validación cruzada, validación anidada para todo componente ajustable y registro en MLflow, lo que hace comparables y reproducibles todas las decisiones.
- Con modelos clásicos, el clasificador de sentimiento mejoró de 0,708 a 0,757 de F1-macro (IC 95 % de la mejora: 0,041–0,057; McNemar, $p \approx 3{,}5 \cdot 10^{-44}$), con la mayor ganancia en la clase negativa (+0,072). El *transformer* RoBERTa-Twitter con ajuste fino elevó el F1-macro a 0,900 ± 0,005 y superó al mejor modelo clásico en los cinco folds ($p \approx 6{,}5 \cdot 10^{-7}$).

- En la etapa B ninguna variable nueva superó al conjunto de Avances II y la optimización bayesiana confirmó que los hiperparámetros estaban en la zona óptima; el *stacking* de cuatro modelos elevó el R^2 a 0,793 y redujo el error absoluto de forma significativa.
- Las variables de interacción con comentarios y la antigüedad dominan la predicción según SHAP, y sin ellas el R^2 desciende a 0,674.
- Los intervalos conformales alcanzan la cobertura nominal (90,3 %) y cuantifican una incertidumbre de un factor de ×6 sobre las vistas, que deberá comunicarse al usuario final.

12. Referencias

Akiba, T., Sano, S., Yanase, T., Ohta, T. y Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. En *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 2623–2631). https://doi.org/10.1145/3292500.3330701

Alemán Viteri, S. B. (2021). Análisis de sentimientos para Twitter con Vader y TextBlob. *Revista Odigos, 2*(3), 9–25. https://doi.org/10.35290/ro.v2n3.2021.494

Angelopoulos, A. N. y Bates, S. (2021). *A gentle introduction to conformal prediction and distribution-free uncertainty quantification*. arXiv. https://doi.org/10.48550/arXiv.2107.07511

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C. y Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS.

Chen, T. y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). https://doi.org/10.1145/2939672.2939785

Hutto, C. J. y Gilbert, E. (2014). VADER: A parsimonious rule-based model for sentiment analysis of social media text. En *Proceedings of the Eighth International AAAI Conference on Weblogs and Social Media* (pp. 216–225).

Kreuzberger, D., Kühl, N. y Hirschl, S. (2023). Machine learning operations (MLOps): Overview, definition, and architecture. *IEEE Access, 11*, 31866–31879. https://doi.org/10.1109/ACCESS.2023.3262138

Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L. y Stoyanov, V. (2019). *RoBERTa: A robustly optimized BERT pretraining approach*. arXiv. https://doi.org/10.48550/arXiv.1907.11692

Loria, S. (2020). *TextBlob: Simplified text processing* [Software]. https://textblob.readthedocs.io

Loureiro, D., Barbieri, F., Neves, L., Espinosa Anke, L. y Camacho-Collados, J. (2022). TimeLMs: Diachronic language models from Twitter. En *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics: System Demonstrations* (pp. 251–260). https://doi.org/10.18653/v1/2022.acl-demo.25

Lundberg, S. M. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems 30* (pp. 4765–4774).

Patil, A. (2022). *YouTube statistics* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/advaypatil/youtube-statistics

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M. y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Pennington, J., Socher, R. y Manning, C. D. (2014). GloVe: Global vectors for word representation. En *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing* (pp. 1532–1543). https://doi.org/10.3115/v1/D14-1162

Wolpert, D. H. (1992). Stacked generalization. *Neural Networks, 5*(2), 241–259. https://doi.org/10.1016/S0893-6080(05)80023-1

Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., von Platen, P., Ma, C., Jernite, Y., Plu, J., Xu, C., Le Scao, T., Gugger, S., . . . Rush, A. M. (2020). Transformers: State-of-the-art natural language processing. En *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations* (pp. 38–45). https://doi.org/10.18653/v1/2020.emnlp-demos.6

Zaharia, M., Chen, A., Davidson, A., Ghodsi, A., Hong, S. A., Konwinski, A., Murching, S., Nykodym, T., Ogilvie, P., Parkhe, M., Xie, F. y Zumar, C. (2018). Accelerating the machine learning lifecycle with MLflow. *IEEE Data Engineering Bulletin, 41*(4), 39–45.