UNIVERSIDAD DE CUNDINAMARCA
ESPECIALIZACIÓN EN INTELIGENCIA ARTIFICIAL
PROCESAMIENTO DE LENGUAJE NATURAL
DOCENTE: PAUL ALEXANDER DÍAZ MONTAÑA

INFORME DE PROYECTO: ESTADÍSTICAS DE YOUTUBE – AVANCES II
PREDICCIÓN DEL DESEMPEÑO DE UN VIDEO A PARTIR DE SUS COMENTARIOS

ESTUDIANTE: YOHAN NICOLÁS GÓMEZ CASTAÑEDA
CC: 1233903906

FECHA: 11 DE OCTUBRE DE 2026
REPOSITORIO: https://github.com/Nicolas2322/proyecto-estadisticas-youtube

Contenido

1. Introducción 3
2. Respuestas a las Preguntas de la Entrega 3
3. Datos, Calidad y Preparación 4
    3.1 Descripción y Preparación de los Datos 4
    3.2 Suficiencia, Acceso y Mejora de los Datos 5
4. Análisis Estadísticos Propuestos 7
5. Arquitectura y Modelos Probados 10
    5.1 Etapa A: Modelos de Sentimiento 10
    5.2 Etapa B: Modelos de Desempeño 10
    5.3 Herramientas para Determinar el Modelo 11
6. Desempeño de los Modelos y Métricas 11
    6.1 Etapa A: Clasificación de Sentimiento 11
    6.2 Etapa B: Predicción del Desempeño del Video 12
    6.3 Ajuste de Hiperparámetros 14
7. Selección de Variables 15
    7.1 Variables Candidatas y Criterio de Exclusión 15
    7.2 Evidencia para la Selección 15
8. ¿Es Suficiente un Solo Modelo? 16
9. Limitaciones y Trabajo Futuro 17
10. Conclusiones 17
11. Referencias 18

Proyecto Estadísticas de YouTube – Avances II: Predicción del Desempeño de un Video a partir de sus Comentarios

1. Introducción

El presente informe documenta el segundo avance del proyecto de la asignatura, cuyo propósito es construir un modelo de procesamiento de lenguaje natural (PLN) capaz de estimar el desempeño de un video de YouTube a partir de la información contenida en sus comentarios. Se empleó el conjunto de datos *YouTube Statistics* de Kaggle (Patil, 2022), compuesto por 1.881 videos de 41 categorías de búsqueda y 18.409 comentarios etiquetados como negativos, neutrales o positivos; tras la depuración se conservaron 1.867 videos y 18.139 comentarios.

La solución se organizó en dos etapas. En la primera (etapa A) un clasificador de sentimiento etiqueta cada comentario; se compararon ocho enfoques y una línea base, y el mejor desempeño correspondió a una máquina de soporte vectorial (SVM) lineal sobre representaciones TF-IDF de palabras y caracteres, con F1-macro de 0,710 y exactitud de 0,784 en validación cruzada, frente a 0,596 y 0,715 del léxico VADER. En la segunda (etapa B) un regresor estima el logaritmo de las vistas a partir de variables agregadas de los comentarios y de metadatos que no dependen del resultado; se compararon cuatro algoritmos con cuatro conjuntos de variables, y el modelo XGBoost alcanzó un R^2 de 0,788 ± 0,016 en validación cruzada y de 0,80 en una partición reservada, lo que equivale a un error típico de un factor de ×2,2 sobre las vistas reales. Una búsqueda en malla de 74 combinaciones confirmó la robustez de estos hiperparámetros, y las curvas de aprendizaje permitieron valorar la suficiencia de los datos.

El hallazgo central es que el tono de los comentarios explica muy poco del alcance de un video (correlación parcial $\rho = 0{,}05$), mientras que la interacción que generan los comentarios es la señal más asociada con las vistas (ρ parcial = 0,59 para el comentario con más likes), junto con la antigüedad y la categoría del video.

2. Respuestas a las Preguntas de la Entrega

La Tabla 1 sintetiza la respuesta a cada una de las preguntas planteadas para la semana 8; las secciones siguientes desarrollan cada punto.

Tabla 1

Respuestas a las preguntas de la entrega

Pregunta	Respuesta
¿Qué análisis estadísticos se pueden hacer?	Diez análisis no triviales (sección 4): transformación log-normal, ley de potencia entre likes y vistas, Kruskal-Wallis por categoría con tamaño del efecto, chi-cuadrado con V de Cramér entre categoría y sentimiento, correlaciones parciales controlando categoría y antigüedad, coeficiente de Gini de la atención entre comentarios y prueba de McNemar entre clasificadores.

Pregunta	Respuesta
¿Cuál fue el modelo seleccionado?	Arquitectura en dos etapas: SVM lineal (TF-IDF de palabras y caracteres) para el sentimiento y XGBoost para predecir $\log_{10}$(vistas). Como complemento, una regresión logística clasifica si el video es exitoso dentro de su categoría.
¿Cuál fue su desempeño y bajo qué métricas?	Etapa A: F1-macro 0,710; exactitud 0,784; F1 ponderado 0,785. Etapa B: R^2 0,788; MAE 0,357 y RMSE 0,497 en $\log_{10}$; ρ de Spearman 0,895. Clasificación de éxito: ROC-AUC 0,863; F1 0,770.
¿Cuántos modelos se probaron?	Dieciséis algoritmos (ocho de sentimiento, cuatro regresores y cuatro clasificadores) más tres líneas base, para un total de 43 configuraciones evaluadas con validación cruzada de cinco particiones (los dos léxicos se evaluaron directamente sobre todo el corpus). Además, la búsqueda en malla evaluó 74 combinaciones de hiperparámetros de los tres modelos seleccionados.
¿Qué herramientas se usaron para determinar el modelo?	Python con pandas, scikit-learn, XGBoost, vaderSentiment, TextBlob, SciPy, statsmodels y matplotlib, en un notebook reproducible publicado en GitHub. La selección se apoyó en validación cruzada (estratificada en la etapa A), búsqueda en malla de hiperparámetros (GridSearchCV) evaluada en una partición reservada, prueba de McNemar, curvas de aprendizaje, importancia por permutación, información mutua y ablación por grupos de variables.
¿Son suficientes los datos y cómo pueden mejorarse? (semana 7)	Son suficientes para un modelo funcional de desempeño, cuya curva de aprendizaje ya se aplana, pero no para el techo del clasificador de sentimiento, cuyo desempeño sigue creciendo con más comentarios. Se proponen la API de datos de YouTube, más comentarios por video, mediciones repetidas y una auditoría de las etiquetas (sección 3.2).
¿Es suficiente un solo modelo?	No. El problema combina dos niveles (comentario y video) y la comparación muestra que el texto y los metadatos por separado rinden menos que su combinación (sección 8).
¿Qué variables se seleccionaron para predecir?	Se evaluaron 37 variables candidatas: 15 agregadas de los comentarios (sentimiento, interacción y estilo), 20 tópicos latentes obtenidos con TF-IDF y SVD, la antigüedad y la categoría. El conjunto final conserva 32, tras retirar las cinco de estilo que no aportaban información. Se excluyeron deliberadamente los likes y el número de comentarios del video por fuga de información (sección 7).

3. Datos, Calidad y Preparación

3.1 Descripción y Preparación de los Datos

El conjunto de datos contiene dos tablas. El archivo `videos-stats.csv` incluye título, identificador, fecha de publicación, palabra clave de búsqueda (*Keyword*, 41 categorías), likes, comentarios y vistas; el archivo `comments.csv` registra para cada video alrededor de diez comentarios destacados con su número de likes y una etiqueta de sentimiento (0 negativo, 1 neutral, 2 positivo). Antes del modelado se aplicaron las siguientes correcciones:

- Duplicados: se eliminaron 12 videos repetidos, que aparecían bajo más de una palabra clave, y 249 pares video-comentario duplicados.
- Valores faltantes y contadores ocultos: se descartaron dos videos sin vistas. Seis videos registran likes = −1 y dos registran comentarios = −1, valor con el que

YouTube indica un contador oculto; estos casos se trataron como faltantes y no como cero, dado que al aplicar el logaritmo producían $-\infty$.

- Limpieza del texto: conversión a minúsculas y eliminación de URL, menciones y caracteres especiales, conservando los signos «!» y «?» por su valor como indicadores de intensidad. Las *stopwords* solo se retiraron al vectorizar tópicos, puesto que términos como «not» o «don't» invierten la polaridad de la frase.
- Variables derivadas: antigüedad del video en días respecto a la fecha más reciente del corpus (24 de agosto de 2022), engagement = (likes + comentarios) / vistas, longitud del comentario, número de emojis y proporción de caracteres no ASCII como aproximación del idioma.

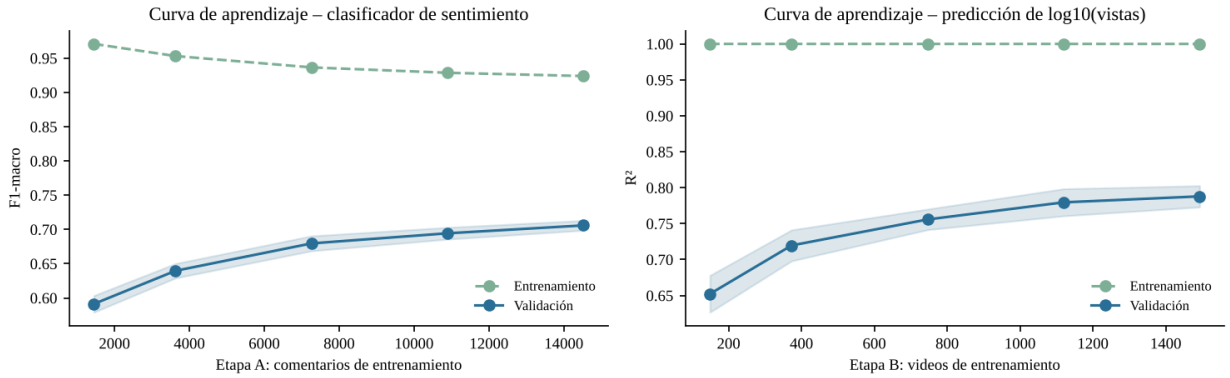
El resultado final comprende 1.867 videos y 18.139 comentarios, con una mediana de diez comentarios por video y fechas de publicación entre 2007 y 2022. Las clases de sentimiento presentan desbalance (61,9 % positivo, 25,3 % neutral y 12,8 % negativo), motivo por el cual se adoptó el F1-macro como métrica principal y se emplearon pesos de clase balanceados.

3.2 Suficiencia, Acceso y Mejora de los Datos

La suficiencia de los datos se valoró desde su cobertura y desde la evolución del desempeño al aumentar el tamaño del entrenamiento. En cuanto a la cobertura, el conjunto presenta cuatro restricciones: (a) cada video aporta como máximo 11 comentarios, que corresponden a los destacados por la plataforma y representan en mediana el 1,2 % del total de comentarios del video, de modo que la muestra está sesgada hacia los comentarios más votados; (b) los datos son una única fotografía tomada alrededor del 24 de agosto de 2022, sin evolución temporal de las métricas; (c) cada categoría reúne en promedio 46 videos (mínimo 15), lo que limita el análisis por nicho; y (d) el 81 % de los comentarios contiene marcadores del inglés y el origen de las etiquetas de sentimiento no está documentado, por lo que su calidad no puede verificarse directamente. La Figura 1 presenta las curvas de aprendizaje de ambas etapas.

Figura 1

Curvas de aprendizaje de la etapa A y de la etapa B



Análisis: en la etapa A el F1-macro de validación crece de forma sostenida (0,591 con 1.452 comentarios, 0,680 con 7.263 y 0,706 con 14.527) sin alcanzar una meseta, lo que indica que más comentarios etiquetados mejorarían el clasificador; la brecha frente al entrenamiento (0,924) corresponde a varianza que también se reduce con más datos. En la etapa B el R^2 pasa de 0,652 con 149 videos a 0,756 con 746 y 0,788 con 1.493, pero el último incremento es de apenas 0,008, es decir, la curva se aplana: agregar más videos del mismo tipo aportaría poco, y la mejora debe venir de información nueva (más comentarios por video, mediciones en el tiempo y metadatos adicionales). El R^2 de entrenamiento cercano a 1,0 muestra además que XGBoost memoriza el conjunto de entrenamiento, por lo que la regularización es relevante. Se concluye que los datos son suficientes para un modelo funcional de desempeño, pero no para alcanzar el techo del clasificador de sentimiento.

En cuanto al acceso, los datos pueden obtenerse por tres vías:

- Kaggle (vía utilizada): descarga directa de los dos archivos CSV del conjunto *YouTube Statistics*.
- API de datos de YouTube v3: el método `videos.list` entrega las estadísticas del video (vistas, likes, comentarios, duración) y `commentThreads.list` devuelve los comentarios paginados, ordenados por relevancia o por fecha, dentro de una cuota diaria por proyecto (Google, s.f.).
- Web scraping de la página del video, alternativa sin cuota pero sujeta a los términos de servicio de la plataforma y más frágil ante cambios en el sitio.

Para mejorar los datos se proponen cinco acciones:

- Ampliar la muestra a cientos de comentarios por video, ordenados por fecha, para medir un sentimiento representativo y no solo el de los comentarios destacados.
- Tomar mediciones repetidas del mismo video (por ejemplo, a 1, 7 y 30 días de publicado), lo que permite la predicción temprana y controla el efecto de la

antigüedad.

- Auditar las etiquetas mediante el re-etiquetado manual de una muestra estratificada y el cálculo del acuerdo con la etiqueta original (kappa de Cohen).
- Enriquecer los metadatos con duración, suscriptores del canal, título, descripción y hora de publicación.
- Detectar el idioma de cada comentario para tratarlo con un modelo multilingüe.

Respecto a la variable que se puede predecir, se evaluaron las dos opciones sugeridas. Con las mismas variables y el mismo algoritmo, el modelo final alcanza un R^2 de 0,787 ± 0,018 para $\log_{10}$(vistas) y de 0,774 ± 0,031 para $\log_{10}$(likes). Se eligió el número de vistas como objetivo principal porque mide el alcance, mientras que los likes son prácticamente una función de las vistas ($\beta = 0{,}88$; $R^2 = 0{,}90$; análisis 2), de modo que predecir una equivale casi a predecir la otra. La tasa de engagement queda como objetivo complementario para las siguientes etapas.

4. Análisis Estadísticos Propuestos

Los análisis se seleccionaron para responder preguntas concretas del problema y no únicamente para describir los datos. La Tabla 2 resume cada análisis, su resultado y la decisión de modelado que justificó.

Tabla 2

Análisis estadísticos realizados e implicaciones para el modelado

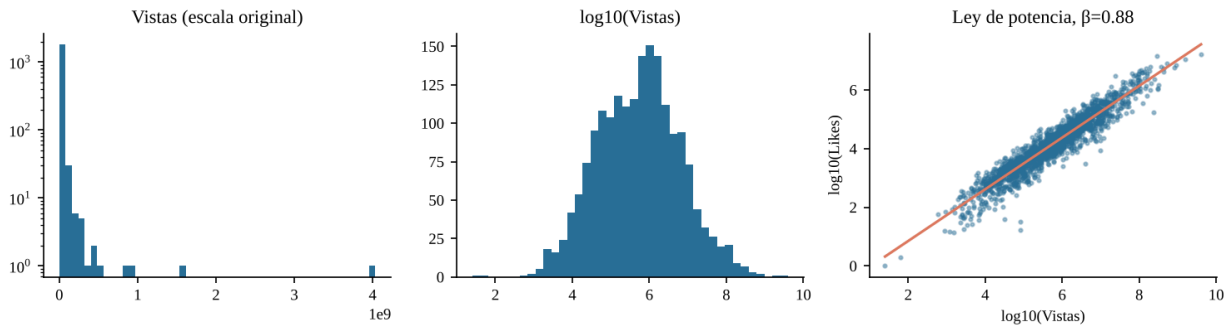
Análisis	**Resultado**	**Implicación para el modelo**
1. Asimetría y normalidad de las métricas	Asimetría de las vistas = 29,5; en $\log_{10}$ desciende a 0,05. Prueba de D'Agostino sobre log(vistas): p = 0,56, por lo que no se rechaza la normalidad.	Las vistas siguen una distribución log-normal; el objetivo se modela como $\log_{10}$(vistas) y los errores se interpretan como factores multiplicativos.
2. Ley de potencia entre likes y vistas (MCO log-log)	Likes $\propto$ Vistas^{0,881} (IC 95 %: 0,868–0,895; $R^2 = 0{,}90$). Comentarios $\propto$ Vistas^{0,719} ($R^2 = 0{,}71$).	Relación sublineal: los videos más vistos tienen proporcionalmente menos interacción (ρ engagement–vistas = −0,43). Likes y vistas constituyen casi la misma señal, de ahí el riesgo de fuga.
3. Kruskal-Wallis de vistas por categoría	$H = 591{,}9$; $p \approx 10^{-99}$; $\varepsilon^2 = 0{,}30$ (efecto grande).	La categoría explica cerca del 30 % de la variación en el orden de las vistas; se incluye como variable y define el éxito relativo.
4. Kruskal-Wallis de engagement por categoría	$H = 668{,}9$; $p \approx 10^{-115}$; $\varepsilon^2 = 0{,}34$.	Cada nicho presenta una cultura de interacción propia, por lo que no conviene un umbral global.

Análisis	Resultado	Implicación para el modelo
5. Chi-cuadrado entre categoría y sentimiento	$\chi^2 = 2.394{,}8$; gl = 80; $p < 0{,}001$; V de Cramér = 0,26 (asociación moderada). Proporción de negativos: *cnn* 55 % y *news* 40 %, frente a *lofi* 2,4 % y *music* 2,6 %.	El sentimiento depende del tema; un comentario negativo en un noticiero no tiene el mismo significado que en un video musical, por lo que el sentimiento se combina con la categoría.
6. Likes de comentarios según sentimiento (Kruskal-Wallis)	H = 207,4; $p \approx 10^{-46}$. Mediana de likes: negativos 65, neutrales y positivos 26. Los negativos son además más extensos (25 palabras frente a 22).	Se evidencia un efecto de amplificación de la controversia: la audiencia premia la crítica. Se crearon variables de sentimiento ponderado por likes.
7. Concentración de la atención (Gini de los likes por video)	Gini mediano = 0,61: pocos comentarios acumulan la mayoría de los likes.	Se incluyen el máximo y el Gini de los likes de comentarios, además del promedio.
8. Correlación parcial con log(vistas), controlando categoría y antigüedad	% positivos: $\rho = 0{,}048$ ($p = 0{,}04$). % negativos: $\rho = 0{,}035$ (n.s.). VADER: $\rho = -0{,}008$ (n.s.). Likes medios de comentarios: $\rho = 0{,}44$. Comentario con más likes: $\rho = 0{,}59$ ($p \approx 10^{-174}$).	Hallazgo central: el tono casi no predice el alcance, mientras que la interacción con los comentarios sí lo hace; esto orienta la selección de variables.
9. Correlaciones de Spearman entre métricas	Vistas–likes 0,95; vistas–comentarios 0,84; vistas–antigüedad 0,63.	La antigüedad es un factor de confusión fuerte, dado que las vistas se acumulan con el tiempo; se controla en todos los modelos.
10. Prueba de McNemar entre el mejor clasificador y VADER	b = 593; c = 350; $\chi^2 = 62{,}1$; $p \approx 3 \cdot 10^{-15}$.	La superioridad del modelo entrenado sobre el léxico es estadísticamente significativa.

Nota. ε^2 = tamaño del efecto épsilon cuadrado; n.s. = no significativo ($p > 0{,}05$); MCO = mínimos cuadrados ordinarios.

Figura 2

Distribución de las vistas y ley de potencia entre likes y vistas

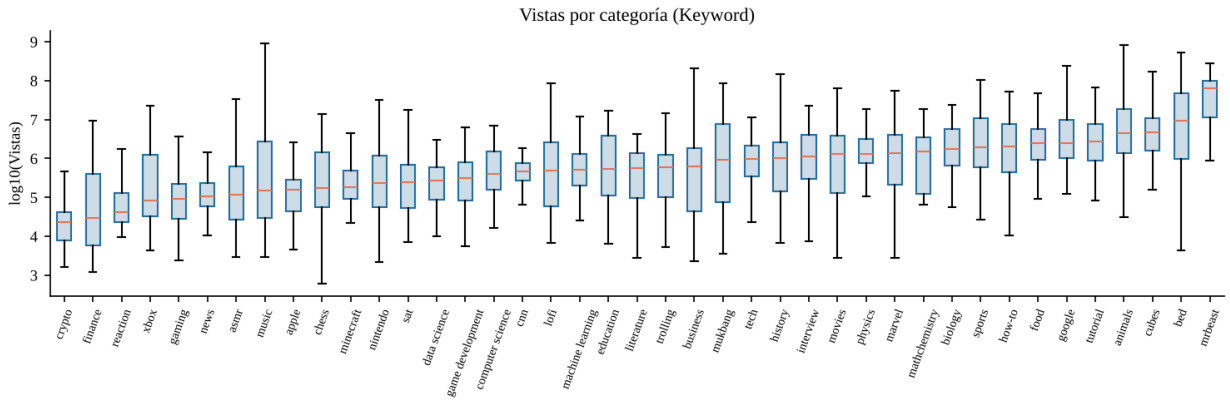


Análisis: en escala original las vistas se concentran cerca de cero con unos pocos valores extremos de hasta 4.000 millones; en escala logarítmica la distribución es prácticamente simétrica, lo que confirma su naturaleza log-normal. El panel derecho muestra que los likes

crecen con un exponente de 0,88, menor que uno, de modo que la tasa de likes por vista disminuye a medida que el video alcanza más audiencia.

Figura 3

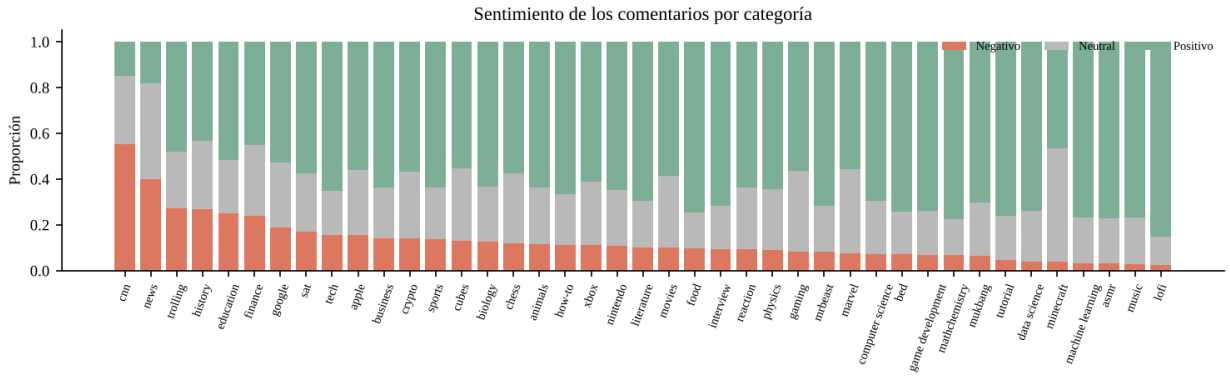
Distribución de log_{10}(vistas) por categoría de búsqueda



Análisis: las categorías están ordenadas por su mediana y exhiben diferencias de más de tres órdenes de magnitud: la mediana de *mrbeast* supera los 65 millones de vistas, seguida de *bed*, *cubes* y *animals*, mientras que temas especializados como *crypto* (23.410), *finance* y *reaction* se ubican en el extremo inferior. El tamaño del efecto ($\varepsilon^2 = 0{,}30$) justifica incluir la categoría como predictor y definir el éxito de un video en relación con su propio nicho.

Figura 4

Proporción de sentimiento de los comentarios por categoría



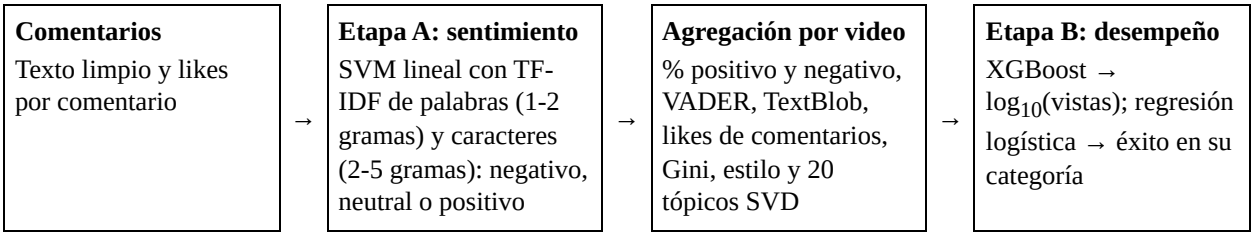
Análisis: las categorías de noticias y política concentran la mayor proporción de comentarios negativos, mientras que música, *lofi* y ASMR son casi exclusivamente positivas. La asociación moderada (V de Cramér = 0,26) indica que el sentimiento debe interpretarse en el contexto de la categoría.

5. Arquitectura y Modelos Probados

La solución se estructuró como una canalización de dos etapas, representada en la Figura 5.

Figura 5

Arquitectura en dos etapas del modelo propuesto



Análisis: para evitar fuga de información entre etapas, las variables de sentimiento por video se calcularon con predicciones *out-of-fold* de la etapa A y no con la etiqueta original. De esta manera el modelo de la etapa B recibe la misma información que tendría en producción, donde los comentarios nuevos llegan sin etiqueta.

5.1 Etapa A: Modelos de Sentimiento

Se evaluaron nueve configuraciones agrupadas en tres familias:

- Modelos basados en léxico, sin entrenamiento: VADER (Hutto y Gilbert, 2014) y TextBlob (Loria, 2020), los mismos que compara Alemán Viteri (2021), con los umbrales estándar de ±0,05 sobre la polaridad.
- Modelos supervisados sobre TF-IDF: Naive Bayes multinomial, Complement Naive Bayes (diseñado para clases desbalanceadas), regresión logística, SVM lineal, SVM lineal con n-gramas de caracteres y Random Forest. Los primeros cuatro corresponden a los algoritmos que compara la literatura revisada (Romero, 2021, como se citó en Alemán Viteri, 2021).
- Línea base: predicción constante de la clase mayoritaria.

5.2 Etapa B: Modelos de Desempeño

Se evaluaron cuatro algoritmos (Ridge, Random Forest, HistGradientBoosting y XGBoost) en dos tareas: una regresión de $\log_{10}$(vistas) y una clasificación que determina si el video supera la mediana de vistas de su propia categoría, con lo cual se elimina el efecto del tema. Cada algoritmo se probó con cuatro conjuntos de variables concebidos como experimento de ablación (solo metadatos, solo PLN, PLN más metadatos y una referencia con likes y comentarios del video), además de dos líneas base (media y azar estratificado), para un total de 34 configuraciones.

5.3 Herramientas para Determinar el Modelo

- Validación cruzada de cinco particiones, estratificada en la etapa A, con semilla fija (42) para garantizar la reproducibilidad; se reportan la media y la desviación estándar entre particiones.
- Partición reservada del 20 % para la matriz de confusión, el reporte por clase y la importancia por permutación.
- Prueba de McNemar para comparar dos clasificadores sobre los mismos ejemplos.
- Búsqueda en malla de hiperparámetros (`GridSearchCV`) sobre el 80 % de entrenamiento, con evaluación final en el 20 % reservado, y curvas de aprendizaje (`learning_curve`) para valorar la suficiencia de los datos.
- Información mutua como filtro de variables, importancia por permutación con 20 repeticiones y ablación por grupos para cuantificar el aporte de cada familia de variables.
- Librerías de Python: scikit-learn (Pedregosa et al., 2011) con `Pipeline`, `ColumnTransformer` y `cross_validate`; XGBoost (Chen y Guestrin, 2016); vaderSentiment; TextBlob; SciPy; statsmodels; matplotlib y joblib. El código se publicó en el repositorio del proyecto como scripts y como un notebook ejecutado, compatible con Google Colab.

6. Desempeño de los Modelos y Métricas

6.1 Etapa A: Clasificación de Sentimiento

Se adoptó el F1-macro como métrica principal, puesto que otorga el mismo peso a la clase negativa, que es minoritaria; se reportan además la exactitud y el F1 ponderado (Tabla 3).

Tabla 3

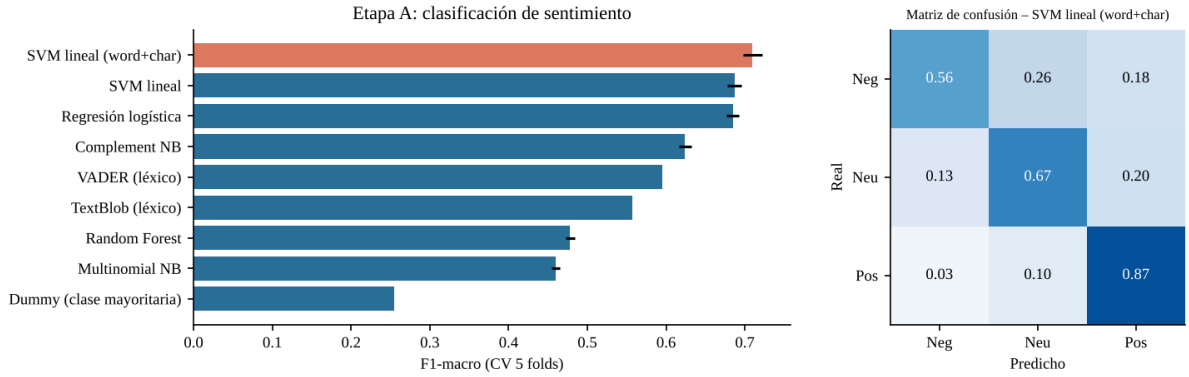
Desempeño de los modelos de clasificación de sentimiento en validación cruzada

Modelo	F1-macro	Exactitud	F1 ponderado	Tiempo (s)
SVM lineal (palabras + caracteres)	**0,710 ± 0,012**	**0,784 ± 0,008**	**0,785**	36
SVM lineal (palabras)	0,687 ± 0,009	0,771 ± 0,005	0,770	7
Regresión logística	0,685 ± 0,008	0,762 ± 0,005	0,765	23
Complement Naive Bayes	0,624 ± 0,008	0,737 ± 0,005	0,722	5
VADER (léxico)	0,596	0,715	0,694	–
TextBlob (léxico)	0,557	0,671	0,666	–
Random Forest	0,478 ± 0,006	0,700 ± 0,003	0,645	158
Naive Bayes multinomial	0,460 ± 0,005	0,681 ± 0,002	0,617	6
Línea base (clase mayoritaria)	0,255	0,619	0,473	–

Nota. Valores expresados como media ± desviación estándar en cinco particiones. En negrita, el modelo seleccionado. Los léxicos no requieren entrenamiento y se evaluaron sobre el corpus completo.

Figura 6

F1-macro por modelo y matriz de confusión del modelo seleccionado



Análisis: en la partición reservada (exactitud 0,779) el F1 por clase del SVM es de 0,875 para positivos, 0,653 para neutrales y 0,571 para negativos. La confusión más frecuente es negativo → neutral (26 %), asociada a sarcasmo, críticas formuladas como pregunta y comentarios políticos sin palabras abiertamente negativas. Los n-gramas de caracteres aportan 2,3 puntos de F1-macro porque capturan emojis, alargamientos y errores ortográficos. A diferencia de lo reportado por Alemán Viteri (2021) en Twitter, en este corpus VADER supera a TextBlob (0,596 frente a 0,557), aunque ambos léxicos quedan por debajo de los modelos supervisados, lo que confirma la importancia del entrenamiento en el dominio. Random Forest y Naive Bayes multinomial presentan exactitudes aceptables pero un F1-macro bajo, ya que casi nunca predicen la clase negativa, lo que ilustra por qué la exactitud por sí sola resulta engañosa con clases desbalanceadas. Los términos más asociados a cada clase según la regresión logística son *worst, hate, ridiculous, bad, terrible* (negativo), *love, great, amazing, thanks, awesome* (positivo) y *did you, is it, link, basically, maybe* (neutral).

6.2 Etapa B: Predicción del Desempeño del Video

Para la regresión se emplearon R^2, error absoluto medio (MAE) y raíz del error cuadrático medio (RMSE) sobre $\log_{10}$(vistas); un MAE de 0,357 equivale a un error multiplicativo típico de $10^{0,357} \approx \times 2,3$. Para la clasificación de éxito relativo se utilizaron ROC-AUC y F1 (Tabla 4).

Tabla 4

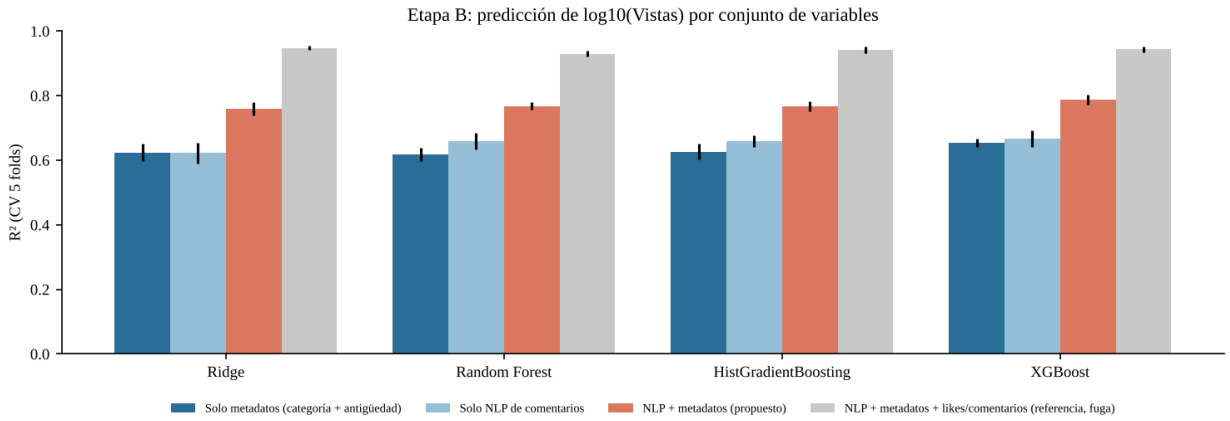
Desempeño de los modelos de la etapa B según el conjunto de variables

Algoritmo y conjunto de variables	R^2	MAE	RMSE	ROC-AUC	F1
Línea base (media / azar)	0,000	0,870	1,079	0,520	0,519
XGBoost, solo metadatos	0,654 ± 0,013	0,476	0,635	0,810	0,719
XGBoost, solo PLN de comentarios	0,668 ± 0,025	0,459	0,622	0,816	0,735
Ridge / regresión logística, PLN + metadatos	0,759 ± 0,021	0,371	0,529	**0,863**	**0,770**
Random Forest, PLN + metadatos	0,768 ± 0,012	0,381	0,520	0,838	0,747
HistGradientBoosting, PLN + metadatos	0,767 ± 0,016	0,371	0,520	0,853	0,758
XGBoost, PLN + metadatos	**0,788 ± 0,016**	**0,357**	**0,497**	0,857	0,755
XGBoost, + likes y comentarios del video (fuga)	*0,944 ± 0,009*	*0,186*	*0,255*	*0,939*	*0,852*

Nota. R^2, MAE y RMSE corresponden a la regresión de $\log_{10}$(vistas); ROC-AUC y F1, a la clasificación de éxito relativo. En la fila lineal, la regresión usa Ridge y la clasificación usa regresión logística. La última fila se presenta solo como techo de referencia. Las demás combinaciones se encuentran en `resultados.json`.

Figura 7

R^2 en validación cruzada por algoritmo y conjunto de variables



Análisis: todos los modelos superan con amplitud la línea base. Las variables de comentarios por sí solas (R^2 = 0,67) explican tanto como los metadatos (0,65), y su combinación alcanza 0,79, lo que demuestra que ambas fuentes aportan información complementaria. Con las mismas variables el orden de los algoritmos se mantiene (XGBoost > Random Forest ≈ HistGradientBoosting > Ridge), y la diferencia de 0,03 en R^2 entre XGBoost y Ridge sugiere efectos no lineales e interacciones moderadas. En la partición reservada XGBoost obtuvo R^2 = 0,80, MAE = 0,338 (factor ×2,18) y ρ de Spearman = 0,895, es decir, ordena muy bien los videos aunque no acierte la magnitud exacta. En la clasificación de éxito relativo la regresión logística (AUC = 0,863) supera ligeramente a los modelos de árboles y es la más estable entre particiones (± 0,001), por lo que se selecciona para esa tarea.

6.3 Ajuste de Hiperparámetros

Para verificar que los valores fijados inicialmente no limitaban el desempeño, se aplicó una búsqueda en malla con validación cruzada de cinco particiones sobre el 80 % de entrenamiento; el modelo resultante se evaluó en el 20 % reservado, que no participó en la búsqueda. Cuando el óptimo quedaba en el borde de la malla, el rango se amplió y la búsqueda se repitió; solo el número de árboles quedó en el límite superior, pero 800 y 1.200 árboles obtienen el mismo R^2 (0,767), por lo que no se justificó ampliarlo más. La Tabla 5 resume los resultados.

Tabla 5

Búsqueda en malla de hiperparámetros y evaluación en la partición reservada

Modelo	Malla explorada	Comb.	Mejor configuración	CV (80 %)	Reservada inicial	Reservada ajustada
SVM lineal (etapa A)	C ∈ {0,03; 0,05; 0,1; 0,2; 0,3; 0,5; 1,0}; n-gramas de caracteres (2-5) o (1-4)	14	C = 0,1; caracteres (2-5)	0,698	0,700	0,700
XGBoost (etapa B)	Profundidad {4; 6; 8}; tasa de aprendizaje {0,03; 0,06; 0,1}; árboles {400; 800; 1.200}; peso mínimo por hoja {1; 5}	54	Profundidad 6; tasa 0,06; 1.200 árboles; peso mínimo 1	0,767	0,801	0,800
Regresión logística (éxito relativo)	C ∈ {0,01; 0,1; 1; 10; 100; 1.000}	6	C = 100	0,873	0,870	**0,890**

Nota. Métrica por fila: F1-macro (SVM), R^2 sobre $\log_{10}$(vistas) (XGBoost) y ROC-AUC (regresión logística). Comb. = combinaciones evaluadas, 74 en total. Reservada inicial = desempeño con los hiperparámetros fijados manualmente.

En el SVM y en XGBoost la ganancia es nula (diferencias ≤ 0,001): los valores fijados manualmente ya se encontraban en la zona óptima y la superficie de respuesta es plana, pues las cinco mejores configuraciones de XGBoost difieren en menos de 0,001 de R^2. Esto confirma que la elección de los modelos no es un artefacto de los hiperparámetros. En la regresión logística, una regularización más débil (C = 100) eleva el ROC-AUC en la partición reservada de 0,870 a 0,890, por lo que se adopta esa configuración. El R^2 de 0,767 obtenido dentro de la búsqueda es menor que el 0,788 de la validación cruzada completa porque cada modelo se entrena con menos videos, lo cual es coherente con la curva de aprendizaje de la Figura 1.

7. Selección de Variables

7.1 Variables Candidatas y Criterio de Exclusión

Las variables candidatas se organizaron en cinco grupos, descritos en la Tabla 6.

Tabla 6

Grupos de variables candidatas y justificación

Grupo	Variables	Justificación
Sentimiento (7)	% positivos y % negativos según la etapa A; media, desviación y media ponderada por likes de VADER; polaridad y subjetividad de TextBlob	Núcleo de PLN que exige el proyecto; combina señales de modelo y de léxico.
Interacción con comentarios (3)	Media y máximo de log(likes de comentarios); Gini de los likes	Análisis 6, 7 y 8: señal más asociada con el alcance.
Estilo del texto (5)	Longitud media, % con pregunta, % con exclamación, emojis por comentario, proporción de caracteres no ASCII	Caracterizan el tipo de audiencia y de conversación.
Tópicos latentes (20)	TF-IDF (1-2 gramas) de los comentarios del video reducido con SVD truncada	Resumen de qué se habla, más allá de cómo se habla.
Metadatos (2)	Antigüedad (log de días) y categoría (codificación *one-hot*)	Análisis 3 y 9: factores de confusión que deben controlarse.
Excluidas	*Likes y número de comentarios del video*	*Fuga de información.*

La exclusión de los likes y del número de comentarios del video obedece a que, según la ley de potencia (análisis 2), likes y vistas presentan una correlación de 0,95: son el mismo resultado medido de otra forma y se observan al mismo tiempo que las vistas. Al incluirlos el R^2 asciende a 0,944, pero el modelo deja de predecir y se limita a convertir likes en vistas; por ello esa configuración solo se reporta como techo de referencia.

7.2 Evidencia para la Selección

La selección se respaldó con tres herramientas complementarias: ablación por grupos (Tabla 7), importancia por permutación e información mutua (Figura 8).

Tabla 7

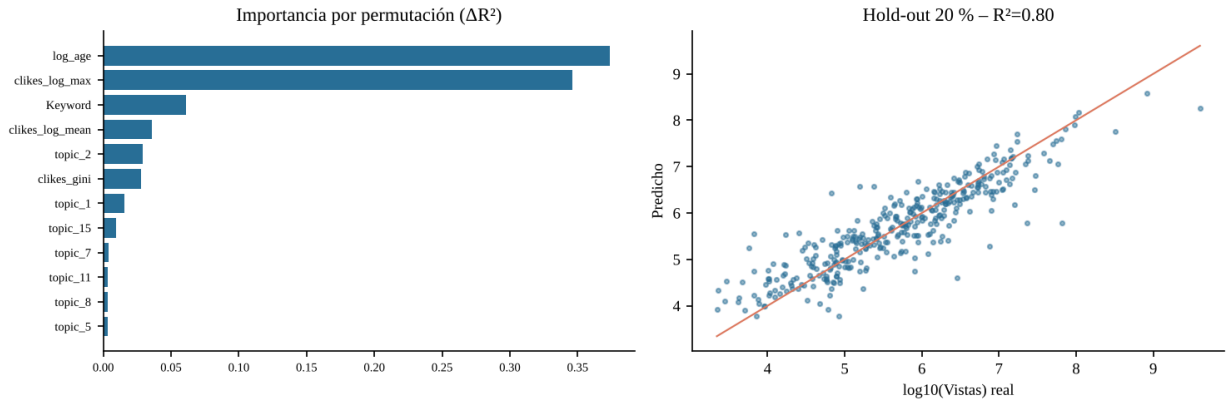
Ablación por grupos de variables sobre el modelo XGBoost

Grupo retirado	R^2 sin el grupo	Pérdida de R^2	Interpretación
Interacción con comentarios	0,685	−0,102	Imprescindible
Antigüedad	0,712	−0,076	Imprescindible
Categoría	0,754	−0,033	Relevante
Tópicos TF-IDF/SVD	0,779	−0,008	Aporte menor
Sentimiento	0,785	−0,002	Casi nulo para el alcance
Estilo del texto	0,787	−0,000	Redundante

Nota. R^2 de referencia con todas las variables: 0,788 (validación cruzada de cinco particiones).

Figura 8

Importancia por permutación y valores reales frente a predichos en la partición reservada



Análisis: los rankings de información mutua y de importancia por permutación coinciden. Las primeras posiciones corresponden al máximo de likes de un comentario (información mutua = 0,46; permutación = 0,35), la antigüedad (0,29; 0,37), el promedio de likes de comentarios (0,26), el Gini (0,11) y la categoría. En consecuencia, el conjunto seleccionado para la etapa B se compone de las variables de interacción, sentimiento, antigüedad, categoría y tópicos. Las variables de sentimiento se conservan pese a su bajo aporte al R^2 por dos razones: el modelo debe ser útil para un creador de contenido, que además del alcance necesita conocer la percepción de la audiencia, y su costo es bajo sin deteriorar la validación cruzada. Las variables de estilo, que no aportan información, se retiraron: con los hiperparámetros ajustados, el modelo con 32 variables obtuvo un R^2 de 0,787 ± 0,018 frente a 0,783 ± 0,013 con las 37, por lo que el conjunto final prescinde de ellas.

8. ¿Es Suficiente un Solo Modelo?

Los resultados indican que un solo modelo no es suficiente, por tres razones:

- Distinta unidad de análisis: el sentimiento se define por comentario y el desempeño por video, por lo que se requiere un clasificador de texto (etapa A) y un modelo tabular sobre los datos agregados (etapa B). Un único modelo de extremo a extremo dispondría de solo 1.867 ejemplos para aprender simultáneamente lenguaje y alcance.
- Información complementaria: ni el modelo de solo texto (R^2 = 0,67) ni el de solo metadatos (0,65) igualan a la combinación (0,79).
- Dos preguntas distintas: «¿cuántas vistas tendrá?» (regresión con XGBoost) y «¿le irá mejor que a los videos de su nicho?» (clasificación con regresión logística, AUC = 0,86) se responden mejor con modelos diferentes. Un ensamble de XGBoost, Random

Forest y HistGradientBoosting podría reducir la varianza, dado que sus errores no están perfectamente correlacionados.

9. Limitaciones y Trabajo Futuro

- Los likes de los comentarios dependen en parte del tamaño de la audiencia. Constituyen una señal legítima, porque se observan en los comentarios y no en el contador del video, pero también reflejan el alcance; en la siguiente entrega se medirá su poder predictivo usando solo comentarios de las primeras horas, escenario realista de predicción temprana.
- Sesgo por antigüedad: la mitad de los videos tiene menos de 72 días y algunos apenas uno o dos, de modo que sus vistas aún no se han estabilizado; se evaluará normalizar por antigüedad (vistas por día).
- Modelos de lenguaje preentrenados: se comparará el SVM con un *transformer* ajustado (DistilBERT o un modelo multilingüe tipo XLM-R) para mejorar la clase negativa (F1 = 0,57), en especial frente al sarcasmo y a comentarios en otros idiomas.
- Validación del ajuste: la búsqueda en malla se evaluó con una única partición reservada; en la semana 9 se aplicará validación cruzada anidada y búsqueda bayesiana para el ajuste del *transformer*.
- Calidad de las etiquetas: al no estar documentado su origen, se auditará una muestra re-etiquetada manualmente antes de entrenar modelos más complejos.
- Operación del modelo: para el producto final se expondrán ambas etapas como API desplegada en la nube, con versionamiento de datos y modelos y monitoreo de la deriva en la distribución del sentimiento.

10. Conclusiones

- Las métricas de YouTube siguen distribuciones log-normales y leyes de potencia sublineales, por lo que el modelado en escala logarítmica es necesario y los likes del video no pueden usarse como predictores sin incurrir en fuga de información.
- El SVM lineal con n-gramas de palabras y caracteres es el mejor clasificador de sentimiento (F1-macro = 0,710) y supera de forma significativa a VADER y TextBlob (McNemar, $p \approx 3 \cdot 10^{-15}$).
- XGBoost con variables de PLN y metadatos explica el 79 % de la varianza de log(vistas) y ordena correctamente los videos ($\rho = 0{,}895$); la regresión logística identifica videos exitosos dentro de su categoría con AUC = 0,863.
- Los datos son suficientes para un modelo funcional de desempeño, cuya curva de aprendizaje se aplana con 1.493 videos, pero el clasificador de sentimiento seguiría

mejorando con más comentarios etiquetados.

- La búsqueda en malla de 74 combinaciones confirmó que los hiperparámetros del SVM y de XGBoost estaban en la zona óptima y elevó el ROC-AUC de la regresión logística a 0,890 en la partición reservada.
- El tono de los comentarios aporta poco a la predicción del alcance, mientras que la interacción que generan (likes y su concentración), la antigüedad y la categoría son los factores determinantes.
- El problema requiere una arquitectura de al menos dos modelos, ya que combina dos unidades de análisis y dos preguntas de negocio diferentes.

11. Referencias

Alemán Viteri, S. B. (2021). Análisis de sentimientos para Twitter con Vader y TextBlob. *Revista Odigos, 2*(3), 9–25. https://doi.org/10.35290/ro.v2n3.2021.494

Chen, T. y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). https://doi.org/10.1145/2939672.2939785

Google. (s.f.). *YouTube Data API: Reference*. Google for Developers. https://developers.google.com/youtube/v3/docs

Hutto, C. J. y Gilbert, E. (2014). VADER: A parsimonious rule-based model for sentiment analysis of social media text. En *Proceedings of the Eighth International AAAI Conference on Weblogs and Social Media* (pp. 216–225).

Loria, S. (2020). *TextBlob: Simplified text processing* [Software]. https://textblob.readthedocs.io

Malik, F. (2019, 21 de junio). NLP: Introduction to NLP & sentiment analysis. *FinTechExplained*. https://medium.com/fintechexplained/sentimental-analysis-an-introduction-7fc21d9b8625

Patil, A. (2022). *YouTube statistics* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/advaypatil/youtube-statistics

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M. y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.